

Федеральное государственное автономное образовательное учреждение  
высшего образования  
«Московский физико-технический институт  
(национальный исследовательский университет)»  
Физтех-школа прикладной математики и информатики  
Кафедра интеллектуальных систем

Терентьев Александр Александрович

**ОБРАТНЫЕ ЗАДАЧИ В МОДЕЛИРОВАНИИ  
НЕЙРОННЫХ ДИФФЕРЕНЦИАЛЬНЫХ УРАВНЕНИЙ  
В ЧАСТНЫХ ПРОИЗВОДНЫХ**

09.04.01 — Информатика и вычислительная техника

Выпускная квалификационная работа магистра

**Научный руководитель:**  
Стрижов Вадим Викторович,  
д-р физ.-мат. наук

Москва — 2026

# 1. Введение

Обратная задача ЭЭГ имеет фундаментальное значение для исследования активности мозга, поскольку она позволяет получить представление о пространственной и временной структуре распределения источников сигнала в мозге при выполнении различных когнитивных и моторных задач. Это позволяет определять аномалии в активности мозга и их причины, что способствует пониманию внутренней работы мозга и выявлению областей с аномалиями проводимости, которые могут указывать на поврежденную ткань [1]. Обратная задача ЭЭГ является плохо обусловленной, поэтому у нее не существует единственного решения, обусловленного ограниченным числом наблюдений на поверхности головы.

Для восстановления приближённого решения необходимо задать модель источников и регуляризующий функционал. В работах MNE [2] и томографии электрической активности низкого разрешения (LORETA) [3] рассматриваются линейные источники и квадратичная регуляризация, учитывающие взаимосвязь между источниками тока и измеренными потенциалами в предположении квазистатического приближения. Есть нейросетевые подходы решющие псевдобротную задачу, но не учитывающие физику электромагнитного сигнала [4]. Целью данной работы является предложить регуляризацию для обратной задачи pPDE, основанную на максимально общей физической модели описания источников поля. Модель источников должна быть достаточно гибкой, чтобы описывать широкий спектр возможных источников сигнала в мозге, включая как локализованные, так и распределенные источники. При этом регуляризация должна быть физически обоснованной, учитывать электромагнитную природу задачи и обеспечивать устойчивость решения [5]. В большинстве работ используется предположение о квазистатичности процессов, происходящих в мозге. В общем случае это неверно. Для моделирования источников коротких сигналов в мозге необходимо учитывать зависимость поля от скорости изменения источников сигнала. Целью работы является предложение такой модели, которая автоматически учитывается зависимость поля от скорости изменения источников сигнала, тем самым описывая эффект индукции от резкого изменения токов.

## 1.1. Определение задачи обратного восстановления ЭЭГ

В общем случае обратная задача ЭЭГ формулируется как задача восстановления непрерывного распределения источников  $s \in \mathcal{S}$  по конечному набору наблюдений  $d \in \mathcal{O}$ . Введём три функциональных пространства.

Пространство источников  $\mathcal{S}$  – гильбертово пространство распределений поляризации  $\mathbf{P}(\mathbf{r}, t)$  в области  $\Omega \subset \mathbb{R}^3$ . Пространство полей  $\mathcal{F}$  – гильбертово пространство потенциалов  $\phi(\mathbf{r}, t)$  и  $\mathbf{A}(\mathbf{r}, t)$ . Пространство наблюдений  $\mathcal{O} = \mathbb{R}^n$  – евклидово пространство измерений на  $n$  датчиках.

Пусть  $T : \mathcal{S} \rightarrow \mathcal{F}$  – оператор прямой задачи, ставящий в соответствие

распределению источников поле, удовлетворяющее уравнениям Максвелла в области  $\Omega$ . Пусть  $C : \mathcal{F} \rightarrow \mathcal{O}$  – оператор наблюдения, проецирующий поле на значения, измеряемые датчиками на границе  $\Gamma = \partial\Omega$ . Тогда оператор наблюдаемой прямой задачи определяется как композиция:

$$K = C \circ T : \mathcal{S} \rightarrow \mathcal{O}. \quad (1)$$

Наблюдаемые данные  $d$  представляются в виде:

$$d = Ks + \eta, \quad (2)$$

где  $\eta \in \mathcal{O}$  — аддитивный шум. Требуется восстановить источник  $s \in \mathcal{S}$  по данным  $d \in \mathcal{O}$ . Оператор  $K$  вырожден, так как множество источников, порождающих одинаковые наблюдения, бесконечно. Для корректной постановки задачи вводится регуляризация, обеспечивающая устойчивость и физическую обоснованность решения.

В задаче ЭЭГ  $T$  является оператором решения уравнений Максвелла, который отображает распределение источников в электромагнитное поле. Из принципа суперпозиции и линейности уравнений Максвелла следует, что  $T$  — линейный оператор. Оператор  $C$  который проецирует поле на значения, измеряемые датчиками. Поле  $y = Ts$  в модели является непрерывным по координатам  $(x, y, z, t)$  в области головы  $\Omega$  [Рисунок 2]. Однако наблюдения  $d$  — это дискретные значения поля на датчиках, расположенных на поверхности головы  $\Gamma$  [Рисунок 1]. Поэтому оператор  $C$  — это дискретизирующий оператор, который отображает непрерывное поле в конечный набор значений на датчиках. В результате оператор  $K = CT$  является композицией непрерывного оператора  $T$  и дискретизирующего оператора  $C$ , что делает его вырожденным [5].




Рис. 1: Поверхность головы  $\Gamma$




Рис. 2: Разрез объема  $\Omega$

## 2. Регуляризация обратной задачи через энергию поля

Из линейности оператора следует, что множество решений прямой задачи для данных  $d$  задаётся

$$\mathcal{X}(d) = \{x \in x_0 + \ker(K)\}, Kx_0 = d.$$

Поэтому в качестве регуляризации предлагается взять квадратичный функционал, который моделирует энергию взаимодействия электромагнитного поля с источниками через положительно определённый оператор потенциала  $T$ :

$$E[f] = \langle Tf, f \rangle_{\mathcal{S}}, \quad (3)$$

где  $Tf$  — поле, генерируемое источниками, а  $f$  — сами источники.

Энергия поля задает слишком большую стоимость для решений, которые создают сильные поля на датчиках, что соответствует физической интуиции о том, что источники с высокой энергией менее вероятны. Но при этом она поощряет некомпактные решения, которые не соответствуют реальным источникам в мозге. Поэтому в качестве дополнительного регуляризатора предлагается использовать функционал полной вариации  $\text{TV}(s)$  [6], который поощряет локализованные и кусочно-постоянные решения.

Пусть  $\mathcal{O}$  — гильбертово пространство наблюдений,  $\mathcal{F}$  — гильбертово пространство полей, и  $\mathcal{S}$  — гильбертово пространство источников. Тогда задача восстановления источников формулируется как оптимизация функционала

$$J(s) = \|Ks - d\|_{\mathcal{O}}^2 + \alpha \langle Ts, s \rangle_{\mathcal{S}} + \beta \text{TV}(s) \rightarrow \min_{s \in \mathcal{S}}, \quad (4)$$

где первый член отвечает за соответствие данным, второй — за энергию взаимодействия поля с источниками и устойчивость модели, а третий — за пространственную структурированность источника,  $\alpha$  — регуляризация высокоэнергетических источников,  $\beta$  — регуляризация некомпактных источников. В случае, если решение  $s$  представлено через нейросеть  $s_{\theta}$ , эта постановка сводится к оптимизации по параметрам  $\theta$ .

На рисунке 3 показана упрощённая схема: оператор  $D$  восстанавливает параметры источников из данных, а  $G$  воспроизводит предсказанное поле. В оператор-терминах  $D$  задаёт обратное отображение из  $\mathcal{O}$  в  $\mathcal{S}$ , а  $G$  реализует прямой оператор  $K = CT$ .

Таким образом, мы формулируем задачу nPDE как поиск решения  $\hat{s}$  функционала (4) в пространстве  $\mathcal{S}$ . Оператор  $K$  имеет ненулевое ядро, что приводит к бесконечному множеству решений, которые соответствуют данным  $d$ , а единственность достигается за счёт регуляризаторов  $T$  и  $\text{TV}$  [4].

$$\chi_i : (N_x \times N_y \times N_z \times T) \xrightarrow{D(\hat{s}|X, \mathcal{D})} \mathcal{S} \xrightarrow{G(\hat{X}|X(t), \hat{s}, \mathcal{D})} \hat{\mathbf{X}}$$

Рис. 3: Модель сигнала ЭЭГ

Формально пространственно-временной ряд  $\chi$  можно записать как ряд поля  $E(\mathbf{r})_t$ . Таким образом задача состоит в нахождении в источниках поля  $E$ .

В работе предлагается использовать уравнения в частных производных для восстановления динамики поля. В общем виде это можно записать так

$$A\left(s, r, t, E, \frac{\partial E}{\partial \mathbf{r}}, \frac{\partial E}{\partial t}, \dot{\phantom{x}}\right) = 0.$$

### 3. Физико информированный подход

Для физически обоснованных решений используется параметризация уравнений Максвелла через потенциалы и поляризацию. Нейросеть аппроксимирует в каждой точке  $(x, y, z, t)$  семь компонент:

$$\phi, \mathbf{A} = (A_x, A_y, A_z), \mathbf{P} = (P_x, P_y, P_z).$$

Поляризация  $\mathbf{P}$  определяет источники, потенциалы  $\phi$  и  $\mathbf{A}$  — поля. Плотность заряда и плотность тока выражаются через поляризацию:

$$\rho = -\operatorname{div} \mathbf{P}, \quad \mathbf{j} = \frac{\partial \mathbf{P}}{\partial t}. \quad (5)$$

Электрическое поле  $\mathbf{E}$  и магнитное поле  $\mathbf{B}$  задаются через потенциалы:

$$\mathbf{E} = -\nabla \phi - \frac{\partial \mathbf{A}}{\partial t}, \quad \mathbf{B} = \nabla \times \mathbf{A}. \quad (6)$$

Параметризация через потенциалы и поляризацию минимизирует число степеней свободы и соответствует дипольной природе источников сигнала в мозге.

Уравнения Максвелла в выбранной постановке принимают вид волновых уравнений для потенциалов:

$$\square \phi = 4\pi \nabla \cdot \mathbf{P}, \quad (7)$$

$$\square \mathbf{A} = -\frac{4\pi}{c} \frac{\partial \mathbf{P}}{\partial t}, \quad (8)$$

где  $\square = \nabla^2 - \frac{1}{c^2} \frac{\partial^2}{\partial t^2}$  — оператор Д’Аламбера. Калибровка Лоренца:

$$\nabla \cdot \mathbf{A} + \frac{1}{c} \frac{\partial \phi}{\partial t} = 0. \quad (9)$$

Традиционная формулировка через поля  $\mathbf{E}$ ,  $\mathbf{B}$  и плотности  $\rho$ ,  $\mathbf{j}$  требует большего числа компонент и не обеспечивает естественной структуры поляризации. Решения уравнений Максвелла ищутся с помощью nPDE[7].

## 4. Операторная постановка и свойства операторов

### 4.1. Оператор решения прямой задачи $T$

Оператор  $T : \mathcal{S} \rightarrow \mathcal{F}$  определяется как  $T\mathbf{P} = (\phi, \mathbf{A})$ , где  $\phi$  и  $\mathbf{A}$  — решения волновых уравнений:

Линейность оператора  $T$  следует из линейности оператора Д'Аламбера  $\square$  и линейности граничных условий. Для любых  $\mathbf{P}_1, \mathbf{P}_2 \in \mathcal{S}$  и скаляров  $\alpha, \beta \in \mathbb{R}$  выполняется:

$$T(\alpha\mathbf{P}_1 + \beta\mathbf{P}_2) = \alpha T\mathbf{P}_1 + \beta T\mathbf{P}_2. \quad (10)$$

Ограниченность оператора  $T$  доказывается с использованием энергетических оценок для волновых уравнений. Рассмотрим норму решения  $(\phi, \mathbf{A}) = T\mathbf{P}$  в пространстве  $\mathcal{F}$ :

$$\|(\phi, \mathbf{A})\|_{\mathcal{F}}^2 = \int_{\Omega} \int_0^T \left( |\phi|^2 + \|\nabla\phi\|^2 + \|\mathbf{A}\|^2 + \|\nabla \times \mathbf{A}\|^2 + \left| \frac{\partial \mathbf{A}}{\partial t} \right|^2 \right) dt d\mathbf{r}. \quad (11)$$

Для волнового уравнения  $\square\phi = 4\pi\nabla \cdot \mathbf{P}$  с нулевыми начальными и граничными условиями справедлива оценка:

$$\|\phi\|_{H^1(\Omega \times [0, T])} \leq C_1 \|\nabla \cdot \mathbf{P}\|_{L^2(\Omega \times [0, T])}, \quad (12)$$

где  $C_1 > 0$  — константа, зависящая от области  $\Omega$  и временного интервала  $[0, T]$ ,  $H^1$  — пространство Соболева. Аналогичная оценка справедлива для  $\mathbf{A}$ :

$$\|\mathbf{A}\|_{H^1(\Omega \times [0, T])} \leq C_2 \left\| \frac{\partial \mathbf{P}}{\partial t} \right\|_{L^2(\Omega \times [0, T])}. \quad (13)$$

Так как  $\|\nabla \cdot \mathbf{P}\|_{L^2} \leq \|\mathbf{P}\|_{H^1}$  и  $\left\| \frac{\partial \mathbf{P}}{\partial t} \right\|_{L^2} \leq \|\mathbf{P}\|_{H^1}$ , то:

$$\|T\mathbf{P}\|_{\mathcal{F}} \leq C_T \|\mathbf{P}\|_{\mathcal{S}}, \quad (14)$$

где  $C_T = \max(C_1, C_2)$  — константа, не зависящая от  $\mathbf{P}$ .

Положительная определённость оператора  $T$  обусловлена физическим смыслом квадратичной формы  $\langle T\mathbf{P}, \mathbf{P} \rangle_{\mathcal{S}}$ , соответствующей энергии взаимодействия поля с источниками:

$$\langle T\mathbf{P}, \mathbf{P} \rangle_{\mathcal{S}} = \int_{\Omega} (\rho\phi + \mathbf{A} \cdot \mathbf{j}) d\mathbf{r} > 0, \quad \forall \mathbf{P} \neq 0. \quad (15)$$

## 4.2. Оператор наблюдения $C$

Оператор  $C : \mathcal{F} \rightarrow \mathcal{O}$  определяется как:

$$C(\phi, \mathbf{A}) = (\phi(\mathbf{r}_1, t), \phi(\mathbf{r}_2, t), \dots, \phi(\mathbf{r}_n, t))^\top, \quad (16)$$

где  $\mathbf{r}_i \in \Gamma = \partial\Omega$  — координаты датчиков. Оператор  $C$  линеен и ограничен.

## 4.3. Композиция операторов $K = C \circ T$

Оператор  $K : \mathcal{S} \rightarrow \mathcal{O}$  определяется как  $K\mathbf{P} = C(T\mathbf{P})$ . Оператор  $K$  линеен, ограничен, и его ранг не превышает  $n = \dim \mathcal{O}$ .

## 4.4. Аппроксимация энергической регуляризации

В работе в качестве регуляризации предлагается использовать энергию электрического поля, формально задаваемую как

$$E = \int_{\Omega} \phi(r) \rho(r) dr.$$

Ее главным вычислительным недостатком является необходимость численного интегрирования по объему  $\Omega$  на каждом шаге оптимизации, и нахождение решения nPDE для нее. Так как на каждом шаге оптимизации мы не можем гарантировать, что решение nPDE будет найдено с заданной точностью, то численное интегрирование может быть неточным и дорогим. Поэтому предлагается использовать стохастическую аппроксимацию Монтекарло для оценки этого интеграла.

**Лемма 1** (Эквивалентность энергии и Монте-Карло оценки через произведение  $\phi\rho$ ). Пусть  $\Omega \subset \mathbb{R}^d$  — измеримое множество с конечным объёмом  $|\Omega| > 0$ . Пусть функции  $\phi, \rho : \Omega \rightarrow \mathbb{R}$  такие, что  $\phi\rho \in L^1(\Omega)$ . Пусть  $r_1, \dots, r_K$  быть i.i.d. точками, выбранными по вероятностной мере  $\mu$  на  $\Omega$  с плотностью  $p(r) > 0$  почти всюду (в частности, допускается равномерная выборка  $p \equiv 1/|\Omega|$ ). Определим

$$E := \int_{\Omega} \phi(r) \rho(r) dr, \quad \hat{E}_K := \frac{1}{K} \sum_{i=1}^K w(r_i) \phi(r_i) \rho(r_i), \quad w(r) = \frac{1}{p(r)}.$$

Тогда выполняются следующие утверждения:

1. (Несмещённость)  $\mathbb{E}[\hat{E}_K] = E$ .
2. (Сходимость)  $\hat{E}_K \xrightarrow{a.s.} E$  при  $K \rightarrow \infty$ ; более того, при  $\mathbb{E}[|w\phi\rho|] < \infty$  имеем  $\hat{E}_K \rightarrow E$  в  $L^1$ .



3. (Случайная погрешность) Если дополнительно  $w\phi\rho \in L^2(\mu)$ , то по центральной предельной теореме

$$\sqrt{K}(\hat{E}_K - E) \xrightarrow{d} \mathcal{N}(0, \sigma^2), \quad \sigma^2 = \text{Var}_\mu(w\phi\rho).$$

Следовательно, типичный масштаб ошибки равен  $O_p(1/\sqrt{K})$ .

4. (Оценка хвостов) Если  $|w(r)\phi(r)\rho(r)| \leq M$  почти наверное, то по неравенству Хёффдинга для суммы независимых ограниченных слагаемых

$$\mathbb{P}(|\hat{E}_K - E| \geq \varepsilon) \leq 2 \exp\left(-\frac{2K\varepsilon^2}{M^2}\right).$$

*Доказательство.* Пункт 1:

$$\mathbb{E}[\hat{E}_K] = \mathbb{E}\left[\frac{1}{K} \sum_{i=1}^K w(r_i)\phi(r_i)\rho(r_i)\right] = \mathbb{E}[w(r)\phi(r)\rho(r)] = \int_{\Omega} \phi(r)\rho(r) dr = E,$$

где на втором шаге использована линейность матожидания и идентичность распределения сэмплов (см. [8]).

Пункт 2: из предположения  $\mathbb{E}[|w\phi\rho|] < \infty$  и закона больших чисел для i.i.d. последовательностей следует сходимость почти наверное  $\hat{E}_K \rightarrow E$  и сходимость в среднем (при дополнительных условиях) — в  $L^1$  (см. [8]).

Пункт 3: при конечной дисперсии  $\text{Var}_\mu(w\phi\rho) = \sigma^2 < \infty$  применима центральная предельная теорема, которая даёт сходимость распределений к нормальной с указанной дисперсией (см. [9]).

Пункт 4: если слагаемые ограничены по модулю  $M$ , то применима версия неравенства Хёффдинга для сумм i.i.d. ограниченных величин, откуда и следует указанная оценка (см. [10]).  $\square$

Для фиксированного множителя регуляризации  $\lambda > 0$  замена непрерывного регуляризатора  $\lambda E$  на дискретную версию  $\lambda \hat{E}_K$  даёт состоятельную аппроксимацию:  $\hat{E}_K \rightarrow E$  при  $K \rightarrow \infty$  и погрешность порядка  $O_p(1/\sqrt{K})$ .

**Замечание 1.** Аппроксимация вида  $\frac{1}{K} \sum_i \phi(r_i)\rho(r_i)$  (для  $p \equiv 1/|\Omega|$ ) даёт простую и эффективную реализацию регуляризатора во время стохастического градиентного спуска и уменьшает вычислительные затраты по сравнению с оценкой полной энергии по сетке.

## 5. Теоретическая основа регуляризации через энергию

### 5.1. Постановка обратной задачи в операторной форме для конечного числа источников и датчиков

Пусть  $\Omega \subset \mathbb{R}^3$  — область, в которой заданы  $m$  точечных источников с комплексными амплитудами  $f_1, f_2, \dots, f_m \in \mathbb{C}$  в точках  $s_1, s_2, \dots, s_m \in \Omega$ . На фиксированной частоте  $\omega > 0$  измеряется одна компонента поля  $E_z$  в двух точках  $r_1, r_2, \dots, r_n \notin \{s_1, s_2, \dots, s_m\}$ . В дискретном приближении значение потенциала от источника описывается функцией  $G(r, s; \omega)$ :

$$d_i = G(r_i, s_1; \omega)f_1 + G(r_i, s_2; \omega)f_2 + \dots + G(r_i, s_m; \omega)f_m, \quad i = 1, 2, \dots, n. \quad (17)$$

Обозначим

$$f = \begin{pmatrix} f_1 \\ f_2 \\ \vdots \\ f_m \end{pmatrix}, \quad d = \begin{pmatrix} d_1 \\ d_2 \\ \vdots \\ d_n \end{pmatrix}, \quad K = \begin{pmatrix} G(r_1, s_1; \omega) & G(r_1, s_2; \omega) & \dots & G(r_1, s_m; \omega) \\ G(r_2, s_1; \omega) & G(r_2, s_2; \omega) & \dots & G(r_2, s_m; \omega) \\ \vdots & \vdots & \ddots & \vdots \\ G(r_n, s_1; \omega) & G(r_n, s_2; \omega) & \dots & G(r_n, s_m; \omega) \end{pmatrix}. \quad (18)$$

Тогда прямая задача записывается компактно как

$$d = Kf. \quad (19)$$

Оператор  $K$  является дискретной версией композиции  $K = CT$ , где  $T$  — оператор решения уравнения Максвелла, а  $C$  — оператор наблюдений на датчиках.

### 5.2. Пример вырожденной геометрии и проблема неединственности

Рассмотрим геометрию задачи для трех источников, при которой функции Грина для трех источников в двух точках наблюдения задаются следующей матрицей:

$$G(r_1, s_1) = g_{11}, G(r_2, s_1) = g_{21}, G(r_1, s_2) = g_{12}, G(r_2, s_2) = g_{22}, G(r_1, s_3) = g_{13}, G(r_2, s_3) = g_{23}. \quad (20)$$

Тогда

$$K = \begin{pmatrix} g_{11} & g_{12} & g_{13} \\ g_{21} & g_{22} & g_{23} \end{pmatrix}, \quad \text{rank}(K) = 2. \quad (21)$$

Множество решений прямой задачи определяется в случае двух источников и двух датчиков как

$$\mathcal{S}(d) = \{f \in \mathbb{C}^2 : f_3 = \frac{f_1(g_{11}d_2 - g_{21}d_1) + f_2(g_{12}d_2 - g_{22}d_1)}{g_{13}d_2 - g_{23}d_1}\}. \quad (22)$$

Это аффинное подпространство размерности один, и невырожденных решений бесконечно много. Формально,  $\ker K = \{(x, y, z) : ax + by + cz = 0\}$ , и к любому решению можно прибавить произвольный элемент ядра, не изменяя данные.

### 5.3. Функционал регуляризации и физика энергии

Для устранения неединственности вводим регуляризованный функционал

$$J(f) = \|Kf - d\|_2^2 + \alpha \frac{1}{2} \|Kf\|_2^2 + \beta(|f_1 - f_2| + |f_1 - f_3| + |f_2 - f_3|), \quad \alpha > 0, \beta \geq 0. \quad (23)$$

Первое слагаемое это невязка между данными и оценки потенциала модели. Второе слагаемое регуляризация энергии поля. В частотной области оно эквивалентно квадратичному штрафу за амплитуду наблюдаемого поля. Третье слагаемое представляет собой дискретный вариант полной вариации, поощряющий схожесть точечных источников и препятствующий неструктурированному разбросу амплитуд.

Подставляя матрицу (21) и вводя вектор наблюдаемого поля

$$s = Kf \in \mathbb{R}^2, \quad (24)$$

функционал (23) переписывается как

$$J(f) = \|s - d\|_2^2 + \frac{\alpha}{2} \|s\|_2^2 + \beta(|f_1 - f_2| + |f_1 - f_3| + |f_2 - f_3|), \quad s = Kf. \quad (25)$$

#### 5.3.1. Явное решение через минимизацию функционала

Минимизируем функционал (23) при  $\beta = 0$ . Энергия взаимодействия представляет произведение источника на потенциал, генерируемый этим источником. В дискретном случае это скалярное произведение  $f^T T^T f$ , где  $T$  — оператор потенциала:

$$J(f) = \|Kf - d\|_2^2 + \frac{\alpha}{2} f^T T^T f. \quad (26)$$

Раскроем функционал:

$$J(f) = f^T K^T K f - 2f^T K^T d + \|d\|_2^2 + \frac{\alpha}{2} f^T T^T f. \quad (27)$$

Вычислим градиент по  $f$ :

$$\nabla_f J = 2K^T K f - 2K^T d + \alpha T^T f. \quad (28)$$

Приравняв к нулю, получаем нормальную систему уравнений:

$$(2K^T K + \alpha T^T) f^* = 2K^T d. \quad (29)$$

Матрица  $(2K^T K + \alpha T^T)$  размера  $(3 \times 3)$  является положительно определённой при  $\alpha > 0$ , поскольку  $K^T K$  положительно полуопределена (имеет ранг 2), а  $T^T$  положительно определена, так как энергия поля  $E[f] = f^T T^T f > 0$  при  $f \neq 0$ . Таким образом, система имеет единственное решение  $f^*$ .

**Сравнение с исходным СЛАУ:** исходная система  $Kf = d$  при  $\text{rank}(K) = 2$  имеет бесконечное множество решений, образующих одномерное аффинное подпространство:

$$\mathcal{F}_{\text{original}} = \{f \in \mathbb{R}^3 : Kf = d\}. \quad (30)$$

Регуляризованная задача с энергетическим штрафом  $\alpha f^T T^T f > 0$  имеет единственное решение  $f^*$ , полученное как минимум функционала  $J(f)$ . Это решение, как правило, не принадлежит исходному множеству решений  $\mathcal{F}_{\text{original}}$  при  $\alpha > 0$ , так как энергетический штраф переводит оптимум в точку, которая генерирует наблюдаемое поле с иной амплитудой.

При  $\alpha = 0$  (без энергетической регуляризации) система (29) имеет нулевой правый оператор ( $2K^T K$ ), и множество решений совпадает с исходным:  $\mathcal{F}^* = \mathcal{F}_{\text{original}}$ .

#### 5.4. Аналитическое решение в случае специальной геометрии

Рассмотрим частный случай, где геометрия задачи и энергетический оператор  $T$  допускают упрощённое решение. В частности, если источники расположены симметрично относительно датчиков, или матрица  $T^T$  имеет блочную структуру, то система уравнений (29) может быть решена в явном виде.

Для примера рассмотрим симметричный случай  $f_1 = f_2 = x$  и  $f_3 = 0$ . Подставляя в нормальные уравнения:

$$(2K^T K + \alpha T^T) \begin{pmatrix} x \\ x \\ 0 \end{pmatrix} = 2K^T d. \quad (31)$$

Первые две компоненты уравнения (соответствующие  $f_1$  и  $f_2$ ) дают условия на  $x$ . Первое уравнение (строка 1 матрицы  $(2K^T K + \alpha T^T)$ ):

$$2[g_{11}(g_{11} + g_{12}) + g_{21}(g_{21} + g_{22})]x + \alpha(T^T)_{11}x = 2(g_{11}d_1 + g_{21}d_2). \quad (32)$$

Второе уравнение (строка 2 матрицы):

$$2[g_{12}(g_{11} + g_{12}) + g_{22}(g_{21} + g_{22})]x + \alpha(T^T)_{22}x = 2(g_{12}d_1 + g_{22}d_2). \quad (33)$$

При предположении, что оператор  $T^T$  также имеет симметрию, решение принимает форму:

$$x = \frac{2(d_1 + d_2)}{2(g_{11} + g_{12}) + \alpha\lambda_s}, \quad (34)$$

где  $\lambda_s$  – параметр, зависящий от оператора  $T^T$ .

**Физическая интерпретация:** энергетический штраф  $\alpha f^T T^T f$  уменьшает амплитуду оптимального решения по сравнению с исходным СЛАУ (где  $\alpha = 0$ ). При  $\alpha = 0$  (отсутствие энергетической регуляризации) решение  $f^*$  совпадает с одним из решений исходной системы  $Kf = d$ . При возрастании  $\alpha$  решение переходит в область, где энергия взаимодействия источников уменьшается, что физически соответствует поиску менее энергетичных источников.

### 5.4.1. Аналитическое решение с TV регуляризацией

Рассмотрим полный функционал с TV регуляризацией при  $\beta > 0$ :

$$J(f) = \|Kf - d\|_2^2 + \frac{\alpha}{2} f^T T^T f + \beta(|f_1 - f_2| + |f_1 - f_3| + |f_2 - f_3|). \quad (35)$$

TV регуляризация вводит кусочно-гладкую структуру: она штрафует различия между компонентами источника, поощряя их группировку в однородные блоки.

Для симметричного случая  $f_1 = f_2 = x$  и  $f_3 = 0$  имеем:

$$\text{TV}(f) = |x - x| + |x - 0| + |x - 0| = 2|x|. \quad (36)$$

Подставляя в функционал и опуская константы:

$$J(x) = [(g_{11} + g_{12})x - d_1]^2 + [(g_{21} + g_{22})x - d_2]^2 + \frac{\alpha}{2} \lambda x^2 + 2\beta|x|, \quad (37)$$

где  $\lambda$  — энергетический параметр из оператора  $T^T$  (зависит от геометрии).

Раскроем квадраты и соберём коэффициенты:

$$J(x) = Ax^2 - 2Bx + 2\beta|x| + \text{const}, \quad (38)$$

где

$$A = (g_{11} + g_{12})^2 + (g_{21} + g_{22})^2 + \frac{\alpha}{2} \lambda, \quad B = (g_{11} + g_{12})d_1 + (g_{21} + g_{22})d_2. \quad (39)$$

**Случай 1:**  $x > 0$ . Функционал становится:

$$J(x) = Ax^2 - (2B - 2\beta)x + \text{const}. \quad (40)$$

Условие минимума:

$$\frac{dJ}{dx} = 2Ax - (2B - 2\beta) = 0 \quad \Rightarrow \quad x^* = \frac{B - \beta}{A}. \quad (41)$$

Это решение валидно, если  $x^* > 0$ , т.е.  $B > \beta$ .

**Случай 2:**  $x < 0$ . По симметрии задачи получаем  $x^* = -\frac{B+\beta}{A}$ , что требует  $B < -\beta$ . В физических приложениях обычно  $B > 0$ , поэтому этот случай редко встречается.

**Случай 3:**  $x = 0$ . Функция  $|x|$  не дифференцируема в нуле. Используя субдифференциал:

$$0 \in \partial J(0) \quad \Leftrightarrow \quad 0 \in [-2B - 2\beta, -2B + 2\beta]. \quad (42)$$

Это верно, если  $B \leq \beta$ .

**Итоговое решение при  $\beta > 0$ :**

$$f_1^* = f_2^* = \begin{cases} \frac{B-\beta}{A}, & \text{если } B > \beta, \\ 0, & \text{если } B \leq \beta, \end{cases} \quad f_3^* = 0. \quad (43)$$

Где:

$$A = (g_{11} + g_{12})^2 + (g_{21} + g_{22})^2 + \frac{\alpha}{2}\lambda_s, \quad B = (g_{11} + g_{12})d_1 + (g_{21} + g_{22})d_2. \quad (44)$$

**Физическая интерпретация с TV:** При увеличении коэффициента  $\beta$  источники с малыми амплитудами зануляются, поощряя отбор самых значительных компонент. Пороговое значение  $\beta$  определяет, при каком значении амплитуды источников они начинают зануляться. Это соответствует разреживанию решения, что особенно важно в медицинских приложениях, где источники активности в мозге локализованы и дискретны.

### 5.5. Общая вариационная постановка

Пусть  $\mathcal{S}, \mathcal{F}, \mathcal{O}$  — гильбертовы пространства,  $T : \mathcal{S} \rightarrow \mathcal{F}$  — линейный оператор перехода от источника к полю,  $C : \mathcal{F} \rightarrow \mathcal{O}$  — линейный оператор наблюдения, и  $K = CT : \mathcal{S} \rightarrow \mathcal{O}$  — линейный оператор прямой задачи. Пусть  $T : \mathcal{S} \rightarrow \mathcal{F}$  — положительно определённый самосопряжённый оператор. Тогда предлагаемая вариационная задача формулируется как

$$J(s) = \|Ks - d\|_{\mathcal{O}}^2 + \alpha \frac{1}{2} \langle Ts, s \rangle_{\mathcal{S}} + \beta \text{TV}(s), \quad s \in \mathcal{S}, \quad (45)$$

где  $\text{TV}(s)$  — функционал полной вариации в пространстве источников.

Такое сочетание трёх членов имеет ясную физическую и математическую интерпретацию:

1.  $\|Kf - d\|_{\mathcal{O}}^2$  обеспечивает соответствие данным;
2.  $\langle Tf, f \rangle_{\mathcal{S}}$  моделирует энергию взаимодействия поля с источниками;
3.  $\text{TV}(f)$  вводит структурную регуляризацию, поощряя локализованные и кусочно-постоянные решения.

### 5.6. Единственность решения общей задачи

**Лемма 2.** Пусть  $\mathcal{S}, \mathcal{F}, \mathcal{O}$  — гильбертовы пространства,  $T : \mathcal{S} \rightarrow \mathcal{F}$  и  $C : \mathcal{F} \rightarrow \mathcal{O}$  — ограниченные линейные операторы,  $K = C \circ T : \mathcal{S} \rightarrow \mathcal{O}$  — их композиция. Если  $T$  положительно определён на  $\mathcal{S}$  (то есть  $\langle Tf, f \rangle_{\mathcal{S}} > 0$  для всех  $f \neq 0$ ), то оператор  $A = K^*K + \alpha T$  (при  $\alpha > 0$ ) является положительно определённым и обратимым.

*Доказательство леммы 2.* Для любого  $f \neq 0 \in \mathcal{S}$  имеем:

$$\langle Af, f \rangle_{\mathcal{S}} = \langle K^*Kf, f \rangle_{\mathcal{S}} + \alpha \langle Tf, f \rangle_{\mathcal{S}} = \|Kf\|_{\mathcal{O}}^2 + \alpha \langle Tf, f \rangle_{\mathcal{S}}. \quad (46)$$

По предположению,  $T > 0$  означает  $\langle Tf, f \rangle_{\mathcal{S}} \geq m_T \|f\|_{\mathcal{S}}^2$  для некоторого  $m_T > 0$ . Следовательно,

$$\langle Af, f \rangle_{\mathcal{S}} \geq \alpha m_T \|f\|_{\mathcal{S}}^2 > 0, \quad (47)$$

откуда следует положительная определённость  $A$ .  $\square$

**Теорема 1.** Пусть  $\mathcal{S}, \mathcal{F}$  — гильбертовы пространства,  $\mathcal{O} = \mathbb{R}^n$  — евклидово пространство ( $n$  — конечное число датчиков),  $T : \mathcal{S} \rightarrow \mathcal{F}$  и  $C : \mathcal{F} \rightarrow \mathcal{O}$  — ограниченные линейные операторы,  $T$  — положительно определённый оператор. Пусть  $\alpha > 0$ ,  $\beta \geq 0$  и  $\text{TV} : \mathcal{S} \rightarrow [0, +\infty]$  — выпуклый функционал. Тогда функционал (45) строго выпукл и имеет единственный глобальный минимум.

*Доказательство.* Разложим функционал и проанализируем каждый компонент, используя свойства операторов и конечномерность пространства наблюдений.

**Шаг 1: Анализ квадратичного компонента.**

Рассмотрим

$$F(f) = \|Kf - d\|_{\mathcal{O}}^2 + \frac{\alpha}{2} \langle Tf, f \rangle_{\mathcal{S}}. \quad (48)$$

Первый член — норма в конечномерном евклидовом пространстве  $\mathcal{O} = \mathbb{R}^n$  (где  $n$  — число датчиков). Её можно переписать через сопряжённый оператор  $K^* : \mathcal{O} \rightarrow \mathcal{S}$ :

$$\|Kf - d\|_{\mathcal{O}}^2 = \langle Kf - d, Kf - d \rangle_{\mathcal{O}} = \langle K^*Kf, f \rangle_{\mathcal{S}} - 2\langle K^*d, f \rangle_{\mathcal{S}} + \|d\|_{\mathcal{O}}^2. \quad (49)$$

Оператор  $K^*K$  является композицией  $K^* : \mathbb{R}^n \rightarrow \mathcal{S}$  и  $K : \mathcal{S} \rightarrow \mathbb{R}^n$ . Поскольку  $\mathcal{O} = \mathbb{R}^n$  конечномерно, оператор  $K^*K$  имеет **конечный ранг не выше  $n$** . Он положительно полуопределён:

$$\langle K^*Kf, f \rangle_{\mathcal{S}} = \|Kf\|_{\mathcal{O}}^2 \geq 0 \quad \forall f \in \mathcal{S}. \quad (50)$$

Второй член в  $F$  — энергетический штраф. Поскольку  $T$  положительно определён, имеем:

$$\langle Tf, f \rangle_{\mathcal{S}} > 0 \quad \forall f \neq 0 \in \mathcal{S}. \quad (51)$$

**Шаг 2: Строгая выпуклость  $F$  и роль конечномерности.**

Функционал  $F$  квадратичен:

$$F(f) = \langle Af, f \rangle_{\mathcal{S}} - 2\langle b, f \rangle_{\mathcal{S}} + c, \quad (52)$$

где  $A = K^*K + \frac{\alpha}{2}T$ ,  $b = K^*d$ ,  $c = \|d\|_{\mathcal{O}}^2$ .

Ключевое свойство: оператор  $A$  является суммой оператора  $K^*K$  (конечного ранга, положительно полуопределённого) и оператора  $\frac{\alpha}{2}T$  (положительно

определённого на всём  $\mathcal{S}$ ). При  $\alpha > 0$  энергетический оператор  $T$  дополняет ранга оператора  $K^*K$  до полного ранга. Для любого  $f \neq 0$ :

$$\langle Af, f \rangle_{\mathcal{S}} = \langle K^*Kf, f \rangle_{\mathcal{S}} + \frac{\alpha}{2} \langle Tf, f \rangle_{\mathcal{S}} \geq \frac{\alpha}{2} m_T \|f\|_{\mathcal{S}}^2 > 0, \quad (53)$$

где  $m_T > 0$  — константа такой, что  $\langle Tf, f \rangle_{\mathcal{S}} \geq m_T \|f\|_{\mathcal{S}}^2$  для всех  $f \in \mathcal{S}$  (существует по положительной определённости  $T$ ). Таким образом, оператор  $A$  положительно определён, и квадратичный функционал  $F$  строго выпуклый.

### Шаг 3: Свойства полной вариации.

Функционал полной вариации  $\text{TV} : \mathcal{S} \rightarrow [0, +\infty]$  по определению выпуклый: для всех  $f_1, f_2 \in \mathcal{S}$  и  $\lambda \in [0, 1]$ :

$$\text{TV}(\lambda f_1 + (1 - \lambda)f_2) \leq \lambda \text{TV}(f_1) + (1 - \lambda) \text{TV}(f_2). \quad (54)$$

Кроме того,  $\text{TV}$  является нижнеполунепрерывным функционалом в слабой топологии пространства  $\mathcal{S}$ .

### Шаг 4: Строгая выпуклость суммы.

Сумма

$$J(f) = F(f) + \beta \text{TV}(f) \quad (55)$$

при  $\beta \geq 0$  остаётся строго выпуклой, поскольку  $F$  строго выпукла. Для всех  $f_1 \neq f_2$  и  $\lambda \in (0, 1)$ :

$$J(\lambda f_1 + (1 - \lambda)f_2) < \lambda J(f_1) + (1 - \lambda)J(f_2). \quad (56)$$

### Шаг 5: Коэрцитивность и существование минимума.

Функционал  $J$  коэрцитивен:  $J(f) \rightarrow +\infty$  при  $\|f\|_{\mathcal{S}} \rightarrow \infty$ . Это следует из того, что:

$$J(f) \geq \langle K^*Kf, f \rangle_{\mathcal{S}} + \frac{\alpha}{2} \langle Tf, f \rangle_{\mathcal{S}} - 2\|K^*d\|_{\mathcal{S}}\|f\|_{\mathcal{S}} \geq c_1\|f\|_{\mathcal{S}}^2 - c_2\|f\|_{\mathcal{S}}, \quad (57)$$

где  $c_1 > 0$  — константа положительной определённости  $A$ , а  $c_2$  — ограниченная константа.

Поскольку  $J$  строго выпуклый, нижнеполунепрерывный и коэрцитивный на гильбертовом пространстве  $\mathcal{S}$ , он имеет *единственный* глобальный минимум  $f^* \in \mathcal{S}$ .  $\square$

**Замечание 2.** Теорема 1 подчёркивает ключевую роль энергетического члена  $\frac{\alpha}{2} \langle Tf, f \rangle_{\mathcal{S}}$  в обеспечении единственности решения, особенно в контексте конечного числа датчиков.

1. **Конечномерность пространства наблюдений:** Поскольку  $\mathcal{O} = \mathbb{R}^n$  (где  $n$  — число датчиков), оператор  $K^*K$  имеет конечный ранг, не превышающий  $n$ . Это означает, что ядро оператора  $K$  может быть нетривиальным и иметь размерность  $\dim \ker K = \dim \mathcal{S} - \text{rank}(K) \geq \dim \mathcal{S} - n$ . В частности, при  $\dim \mathcal{S} > n$  (пространство источников имеет большую размерность, чем пространство наблюдений) задача автоматически становится недоопределённой.



2. **Роль энергетического оператора  $T$ :** Энергетический штраф  $\alpha \langle Tf, f \rangle_{\mathcal{S}}$  полностью определён на гильбертовом пространстве  $\mathcal{S}$  и не зависит от конечномерности  $\mathcal{O}$ . Благодаря положительной определённости  $T$ , оператор  $A = K^*K + \frac{\alpha}{2}T$  остаётся положительно определённым, несмотря на ранг оператора  $K$ . Это гарантирует строгую выпуклость функционала  $F$  на всём пространстве  $\mathcal{S}$ .
3. **Недостаточность одной регуляризации:** Без энергетического члена ( $\alpha = 0$ ): при  $\dim \mathcal{S} > n$  функционал  $\|Kf - d\|_{\mathcal{O}}^2$  имеет бесконечномерное множество решений (полное аффинное подпространство размерности  $\dim \mathcal{S} - n > 0$ ). Даже добавление  $TV$ -регуляризации  $\beta TV(f)$  не обеспечивает единственность. Без структурной регуляризации ( $\beta = 0$ ): решение физически неправдоподобное и излишне гладкое в пространстве источников.
4. **Регуляризация при конечном числе датчиков:** Энергетический член обеспечивает единственность решения, компенсируя конечномерности наблюдений, добавляет бесконечномерно ограничение в виде положительно определённой формы, а  $TV$ -регуляризация добавляет структурные ограничения. Вместе они обеспечивают как математическую корректность (единственность, устойчивость), так и физическую обоснованность решения.

## 5.7. Анализ аппроксимации оператора прямой задачи

На практике оператор  $T$  часто аппроксимируется последовательностью  $T_n$  (например, численным решателем или обучаемым суррогатом). Рассмотрим функционалы

$$J_n(f) = \|CT_n f - d\|_{\mathcal{O}}^2 + \frac{\alpha}{2} \langle T_n f, f \rangle_{\mathcal{S}} + \beta TV(f), \quad (58)$$

где  $\mathcal{S}, \mathcal{F}, \mathcal{O}$  — гильбертовы пространства,  $T, T_n : \mathcal{S} \rightarrow \mathcal{F}$  — ограниченные линейные операторы,  $C : \mathcal{F} \rightarrow \mathcal{O}$  — ограниченный линейный оператор наблюдения,  $\alpha > 0$ ,  $\beta \geq 0$ , а  $TV : \mathcal{S} \rightarrow [0, +\infty]$  — выпуклый нижнеполунепрерывный функционал. Оператор  $T$  является положительно определённым оператором потенциала: существует  $m_T > 0$  такое, что  $\langle Tf, f \rangle_{\mathcal{S}} \geq m_T \|f\|_{\mathcal{S}}^2$  для всех  $f \in \mathcal{S}$ . Квадратичная форма  $\langle Tf, f \rangle_{\mathcal{S}}$  соответствует энергии взаимодействия поля с источниками.

**Теорема 2** (Сходимость минимизаторов). Пусть выполнены следующие условия:

1.  $T_n \rightarrow T$  равномерно на ограниченных множествах  $\mathcal{S}$ , то есть  $\forall R > 0$ :  $\sup_{\|f\|_{\mathcal{S}} \leq R} \|T_n f - T f\|_{\mathcal{F}} \rightarrow 0$  при  $n \rightarrow \infty$ .

2. Существует  $M > 0$  такое, что  $\sup_n \|T_n\|_{\mathcal{L}(\mathcal{S}, \mathcal{F})} \leq M$  (равномерная ограниченность).
3. Оператор  $C : \mathcal{F} \rightarrow \mathcal{O}$  ограничен.
4. Оператор  $T$  положительно определён:  $\exists m_T > 0$  такое, что  $\langle Tf, f \rangle_{\mathcal{S}} \geq m_T \|f\|_{\mathcal{S}}^2$  для всех  $f \in \mathcal{S}$  (коэрцитивность энергетического члена).
5. Функционал  $\text{TV}$  ограничен снизу и коэрцитивен:  $\text{TV}(f) \geq c\|f\|_{\mathcal{S}} - d$  для некоторых  $c > 0, d \geq 0$ .

Обозначим  $J(f) = \|CTf - d\|_{\mathcal{O}}^2 + \frac{\alpha}{2} \langle Tf, f \rangle_{\mathcal{S}} + \beta \text{TV}(f)$ . Пусть  $f_n^*$  — единственный глобальный минимум  $J_n$ , а  $f^*$  — единственный глобальный минимум  $J$ . Тогда  $f_n^* \rightarrow f^*$  сильно в норме  $\mathcal{S}$  при  $n \rightarrow \infty$ .

**Доказательство. 1. Коэрцитивность и ограниченность.** Для любого  $f \in \mathcal{S}$  имеем

$$\begin{aligned} J_n(f) &\geq \|CT_n f - d\|_{\mathcal{O}}^2 + \frac{\alpha}{2} \langle T_n f, f \rangle_{\mathcal{S}} + \beta \text{TV}(f) \\ &\geq \frac{\alpha}{2} \langle T_n f, f \rangle_{\mathcal{S}} + \beta(c\|f\|_{\mathcal{S}} - d). \end{aligned}$$

Так как семейство  $\{T_n\}$  равномерно ограничено, существует константа  $C_1 > 0$  такая, что  $|\langle T_n f, f \rangle_{\mathcal{S}}| \leq C_1 \|f\|_{\mathcal{S}}^2$ . По условию (4) для точного оператора  $T$  имеем  $\langle Tf, f \rangle_{\mathcal{S}} \geq m_T \|f\|_{\mathcal{S}}^2$ . В силу равномерной сходимости  $T_n \rightarrow T$  на шарах, можно показать, что существует  $N$  и  $\tilde{m} > 0$  такие, что для всех  $n \geq N$  и всех  $f \in \mathcal{S}$ :

$$\langle T_n f, f \rangle_{\mathcal{S}} \geq \tilde{m} \|f\|_{\mathcal{S}}^2. \quad (59)$$

Следовательно, для больших  $n$  функционалы  $J_n$  коэрцитивны:

$$J_n(f) \geq \frac{\alpha}{2} \tilde{m} \|f\|_{\mathcal{S}}^2 + \beta c \|f\|_{\mathcal{S}} - \beta d - C_2 \rightarrow +\infty \quad \text{при } \|f\|_{\mathcal{S}} \rightarrow \infty. \quad (60)$$

Поскольку  $J_n(f_n^*) \leq J_n(0) = \|d\|_{\mathcal{O}}^2 + \beta \text{TV}(0) < \infty$ , последовательность  $\{f_n^*\}$  ограничена в  $\mathcal{S}$ .

**2. Слабая сходимость подпоследовательности.** Так как  $\mathcal{S}$  рефлексивно, из ограниченной последовательности можно выделить слабо сходящуюся подпоследовательность (обозначаем её также  $\{f_n^*\}$ ):  $f_n^* \rightharpoonup \bar{f}$  в  $\mathcal{S}$ .

**3. Нижний предел функционалов.** Функционал  $f \mapsto \|CTf - d\|_{\mathcal{O}}^2$  непрерывен по сильной топологии и, следовательно, слабо нижнеполунепрерывен. Функционал  $f \mapsto \langle Tf, f \rangle_{\mathcal{S}}$  является квадратичной формой, соответствующей ограниченному самосопряженному оператору  $T$  (так как  $T$  положительно определён), и также слабо нижнеполунепрерывен. Функционал  $\text{TV}$  по условию слабо нижнеполунепрерывен. Сумма слабо нижнеполунепрерывных функционалов является слабо нижнеполунепрерывной. Поэтому

$$J(\bar{f}) \leq \liminf_{n \rightarrow \infty} J(f_n^*). \quad (61)$$

**4. Оценка  $\limsup$ .** Так как  $f_n^*$  — минимум  $J_n$ , для любого  $f \in \mathcal{S}$  (в частности для  $f^*$ ) имеем  $J_n(f_n^*) \leq J_n(f)$ . Значит,

$$\limsup_{n \rightarrow \infty} J_n(f_n^*) \leq \limsup_{n \rightarrow \infty} J_n(f^*). \quad (62)$$

Поскольку  $T_n \rightarrow T$  равномерно на ограниченных множествах, а  $f^*$  фиксирован,  $T_n f^* \rightarrow T f^*$  сильно в  $\mathcal{F}$ . Тогда  $\|CT_n f^* - d\|_{\mathcal{O}}^2 \rightarrow \|CT f^* - d\|_{\mathcal{O}}^2$  и  $\langle T_n f^*, f^* \rangle_{\mathcal{S}} \rightarrow \langle T f^*, f^* \rangle_{\mathcal{S}}$ . Следовательно,  $\limsup_{n \rightarrow \infty} J_n(f^*) = J(f^*)$ .

**5. Предел.** Собираем неравенства:

$$J(\bar{f}) \leq \liminf_{n \rightarrow \infty} J_n(f_n^*) \leq \limsup_{n \rightarrow \infty} J_n(f_n^*) \leq J(f^*). \quad (63)$$

Так как  $f^*$  — единственный глобальный минимум  $J$ , имеем  $J(\bar{f}) \geq J(f^*)$ . Отсюда  $J(\bar{f}) = J(f^*)$  и  $\bar{f} = f^*$ .

**6. Сильная сходимость.** Все слабые предельные точки последовательности  $\{f_n^*\}$  совпадают с  $f^*$ , следовательно,  $f_n^* \rightharpoonup f^*$  в  $\mathcal{S}$ . Остаётся доказать сильную сходимость. Рассмотрим разность:

$$\begin{aligned} \frac{\alpha}{2} \langle T_n f_n^*, f_n^* \rangle_{\mathcal{S}} - \frac{\alpha}{2} \langle T f^*, f^* \rangle_{\mathcal{S}} &= J_n(f_n^*) - \|CT_n f_n^* - d\|_{\mathcal{O}}^2 - \beta \text{TV}(f_n^*) \\ &\quad - (J(f^*) - \|CT f^* - d\|_{\mathcal{O}}^2 - \beta \text{TV}(f^*)). \end{aligned}$$

Так как  $J_n(f_n^*) \rightarrow J(f^*)$  (из цепочки неравенств выше),  $\|CT_n f_n^* - d\|_{\mathcal{O}}^2 \rightarrow \|CT f^* - d\|_{\mathcal{O}}^2$  (по слабой сходимости и компактности:  $T_n f_n^* = (T_n - T)f_n^* + T f_n^*$ . Первое слагаемое стремится к нулю по равномерной сходимости  $T_n \rightarrow T$  на ограниченных множествах, второе слабо сходится к  $T f^*$ . Тогда  $CT_n f_n^* \rightharpoonup CT f^*$  в  $\mathcal{O}$ , а норма квадрата слабо нижнеполунепрерывна, но предел значений известен. Можно использовать стандартный аргумент: если  $u_n \rightharpoonup u$  и  $\|u_n\| \rightarrow \|u\|$ , то  $u_n \rightarrow u$  сильно. Здесь  $u_n = CT_n f_n^*$ ,  $u = CT f^*$ . Равенство пределов норм следует из сходимости значений функционалов.) и  $\text{TV}(f_n^*) \rightarrow \text{TV}(f^*)$  (так как  $\text{TV}$  слабо нижнеполунепрерывен и пределы совпадают), получаем

$$\langle T_n f_n^*, f_n^* \rangle_{\mathcal{S}} \rightarrow \langle T f^*, f^* \rangle_{\mathcal{S}}. \quad (64)$$

Разложим:

$$\langle T_n f_n^*, f_n^* \rangle_{\mathcal{S}} = \langle T f_n^*, f_n^* \rangle_{\mathcal{S}} + \langle (T_n - T) f_n^*, f_n^* \rangle_{\mathcal{S}}. \quad (65)$$

Второе слагаемое стремится к нулю, так как  $\|(T_n - T) f_n^*\|_{\mathcal{F}} \rightarrow 0$  (равномерная сходимость на ограниченных множествах). Следовательно,  $\langle T f_n^*, f_n^* \rangle_{\mathcal{S}} \rightarrow \langle T f^*, f^* \rangle_{\mathcal{S}}$ . Так как форма  $\langle T \cdot, \cdot \rangle_{\mathcal{S}}$  коэрцитивна (условие 4), это влечёт сильную сходимость  $f_n^* \rightarrow f^*$  в  $\mathcal{S}$ .  $\square$

## 5.8. Схема решения обратной задачи

Рассмотрим обратную задачу восстановления распределения источников  $s \in \mathcal{S}$  по наблюдаемым данным  $d \in \mathcal{O}$  в рамках операторной постановки

$d = Ks + \eta$ , где  $K = C \circ T$  — композиция оператора решения прямой задачи  $T : \mathcal{S} \rightarrow \mathcal{F}$  и оператора наблюдения  $C : \mathcal{F} \rightarrow \mathcal{O}$ . Для обеспечения единственности и устойчивости решения вводится регуляризованный функционал:

$$J(s) = \|Ks - d\|_{\mathcal{O}}^2 + \alpha \mathcal{R}_E(s) + \beta \mathcal{R}_{TV}(s), \quad (66)$$

где  $\mathcal{R}_E(s) = \langle Ts, s \rangle_{\mathcal{S}}$  — энергетический регуляризатор,  $\mathcal{R}_{TV}(s)$  — функционал полной вариации,  $\alpha > 0$  и  $\beta \geq 0$  — параметры регуляризации.

### 5.8.1. Аппроксимация оператора прямой задачи и сходимость решений

Пусть оператор прямой задачи  $T$  аппроксимируется последовательностью операторов  $T_n : \mathcal{S} \rightarrow \mathcal{F}$ , сходящихся к  $T$  в равномерной операторной топологии на ограниченных множествах. Введём аппроксимированный оператор наблюдения  $K_n = C \circ T_n$  и соответствующий регуляризованный функционал:

$$J_n(s) = \|K_n s - d\|_{\mathcal{O}}^2 + \alpha \langle T_n s, s \rangle_{\mathcal{S}} + \beta \mathcal{R}_{TV}(s). \quad (67)$$

Минимизация функционала  $J_n(s)$  по  $s \in \mathcal{S}$  эквивалентна решению вариационной задачи:

$$s_n^* = \arg \min_{s \in \mathcal{S}} J_n(s). \quad (68)$$

Сходимость аппроксимированных решений  $s_n^*$  к точному решению  $s^*$  при  $n \rightarrow \infty$  обеспечивается теоремой о сходимости минимизаторов (см. раздел 4.4).

### 5.8.2. Энергетическая регуляризация и её свойства

Энергетический регуляризатор  $\mathcal{R}_E(s) = \langle Ts, s \rangle_{\mathcal{S}}$  вводится как квадратичная форма, соответствующая положительно определённом оператору потенциала  $T$ . В контексте электромагнитных задач эта форма интерпретируется как энергия взаимодействия поля с источниками:

$$\mathcal{R}_E(s) = \int_{\Omega} (\rho(\mathbf{r})\phi(\mathbf{r}) + \mathbf{A}(\mathbf{r}) \cdot \mathbf{j}(\mathbf{r})) d\mathbf{r}, \quad (69)$$

где  $\rho = -\operatorname{div} \mathbf{P}$  — плотность заряда,  $\mathbf{j} = \partial_t \mathbf{P}$  — плотность тока,  $\phi$  и  $\mathbf{A}$  — скалярный и векторный потенциалы,  $\mathbf{P}$  — поляризация.

Свойства энергетического регуляризатора:

1. **Положительная определённость:**  $\mathcal{R}_E(s) > 0$  для всех  $s \neq 0$ , что обеспечивает строгую выпуклость функционала  $J(s)$ .
2. **Физическая интерпретация:** минимизация  $\mathcal{R}_E(s) = \langle Ts, s \rangle_{\mathcal{S}}$  соответствует поиску решений с минимальной энергией взаимодействия поля

с источниками, что согласуется с принципом наименьшего действия в электродинамике.

3. **Устойчивость:** при  $\alpha > 0$  функционал  $J(s)$  коэрцитивен и имеет единственный минимум даже в случае вырожденного оператора  $K$ .

### 5.8.3. Структурная регуляризация

В работе предлагается кроме энергетической регуляризации использовать функционал полной вариации  $\mathcal{R}_{TV}(s)$  для получения разряженных источников. Без регуляризации на разряженность энергетический член будет способствовать разряженным решениям. Это связано с тем, что для разреженных источников энергия взаимодействия поля с другими источниками минимальна. Так расстояние до дургих будет большим, чем при точечных источниках. А точечные источники как раз дают максимальную энергию. В непрерывном случае функционал полной вариации  $\mathcal{R}_{TV}(s)$  воджится как интеграл нормы градиента функции  $s$ :

$$\mathcal{R}_{TV}(s) = \sum_{\Omega} \|\nabla s(\mathbf{r})\| d\mathbf{r}. \quad (70)$$

В качестве аппроксимации берется лценка Монте-Карло  $\rho = -\operatorname{div} \mathbf{P}$ :

$$\mathcal{R}_{TV}(s) \approx \frac{1}{|\Omega|} \int_{\Omega} \sqrt{\|\nabla \rho(\mathbf{r})\|^2 + \varepsilon} d\mathbf{r}, \quad (71)$$

где  $\varepsilon > 0$  – регуляризационным параметр, устраняющий сингулярность в точке 0.

Функционал обладает следующими

1. **Выпуклость:**  $\mathcal{R}_{TV}(s)$  — выпуклый.
2. **Разреживание:** Минимум функционала  $\mathcal{R}_{TV}(s)$  достигается тогда, когда носитель функции минимален

### 5.8.4. Метод минимизации регуляризованного функционала

Функционал  $J(s)$  минимизируется с помощью градиентного спуска в пространстве  $\mathcal{S}$ . Градиент функционала  $J(s)$  по  $s$  находится как:

$$\nabla_s J(s) = 2K^*(Ks - d) + \alpha T^*s + \beta \partial \mathcal{R}_{TV}(s), \quad (72)$$

где  $K^*$  — сопряжённый оператор к  $K$ ,  $T^*$  — сопряжённый оператор к  $T$ ,  $\partial \mathcal{R}_{TV}(s)$  — субдифференциал функционала полной вариации.

Для численной реализации градиентного спуска вводится последовательность итераций:

$$s^{(k+1)} = s^{(k)} - \gamma_k \nabla_s J(s^{(k)}), \quad (73)$$

где  $\gamma_k > 0$  — шаг градиентного спуска, выбираемый из условия монотонного убывания функционала  $J(s^{(k)})$ . Сходимость итерационного процесса к единственному минимуму  $s^*$  обеспечивается теоремой о сходимости градиентного спуска для строго выпуклых функционалов.

### 5.8.5. Адаптивная регуляризация

В работе необходимо последовательно улучшать аппроксимацию прямой задачи  $T$  и уменьшать невязку для равенства по данным  $Ks = d$ . Предлагается использовать адаптивную регуляризацию в виде мягкой барьерной функции, чтобы делать шаг одновременно в обоих направлениях.

$$\mathcal{B}(s) = \lambda_{\text{data}}(T + \alpha_{\text{data}}T^2), \quad T = \|Ks - d\|_{\mathcal{O}}^2 + \lambda_{\text{time}}\|\partial_t(Ks - d)\|_{\mathcal{O}}^2, \quad (74)$$

где  $\lambda_{\text{data}} > 0$  — параметр барьерной функции,  $\alpha_{\text{data}} > 0$  — коэффициент квадратичного штрафа,  $\lambda_{\text{time}} \geq 0$  — вес временной регуляризации.

Адаптивная настройка параметра  $\lambda_{\text{data}}$  осуществляется на основе оценки невязки данных и точности восстановления оператора  $T$ . Для решения прямой задачи в работе используется метод nPDE. Поэтому оценка точности  $T$  является суммой точности выполнений граничных условий и точности решения уравнения частных производных в области  $\Omega$ . Такой подход обеспечивает баланс между точностью аппроксимации данных и точностью решения прямой задачи.

## 5.9. Граничные условия для прямой задачи

Для решения прямой задачи  $T$  необходимо задать граничные условия на границе области  $\Omega$ . В работе предлагается брать в качестве граничного условия 0 для потенциала  $\phi$  и вектора потенциала  $\mathbf{A}$ , что соответствует условию Дирихле. Такое условие использовать в общем случае неверно. Поэтому предлагается использовать метод идеально согласованного слоя [11]. Он обеспечивает поглощения решения на небольшом слое на границе, без отражения волнового решения от границы. Это позволяет избежать искажения решения, связанного с неверными граничными условиями, и обеспечивает корректность оператора прямой задачи  $T$  в области  $\Omega$ .

### 5.9.1. Теоретическое обоснование сходимости алгоритма

Сходимость предложенного алгоритма обосновывается следующими положениями:

1. **Сходимость аппроксимированных операторов:** при  $T_n \rightarrow T$  минимизаторы  $s_n^*$  функционалов  $J_n(s)$  сходятся к минимизатору  $s^*$  функционала  $J(s)$ .
2. **Единственность решения:** при  $\alpha > 0$  и положительно определённом операторе  $T$  функционал  $J(s)$  строго выпукл и имеет единственный минимум.
3. **Устойчивость к шуму:** регуляризаторы  $\mathcal{R}_E(s)$  и  $\mathcal{R}_{TV}(s)$  обеспечивают устойчивость решения к аддитивному шуму  $\eta$  в данных.
4. **Физическая согласованность:** энергетический регуляризатор  $\mathcal{R}_E(s)$  гарантирует, что решение соответствует принципам электродинамики, а функционал полной вариации  $\mathcal{R}_{TV}(s)$  — структурным особенностям источников сигнала в мозге.

Таким образом, предложенная алгоритмическая схема обеспечивает корректное решение обратной задачи ЭЭГ в рамках физико-информированного подхода, сочетая общность решения с физической интерпретируемостью результатов.

Сначала реализуется барьерное приближение условия  $Kf = d$ , затем условие смягчается и уточняется оператор наблюдения  $K$  аппроксимируемый nPDE. Параметры  $\lambda_{\text{data}}$ ,  $\alpha_{\text{data}}$  и  $\lambda_{\text{time}}$  адаптивно настраиваются в процессе оптимизации для обеспечения баланса между точностью аппроксимации данных и устойчивостью решения. При этом достигается сходимость самого оператора, воостанавливающего решение прямой задачи и решения обратной задачи, удовлетворяющее данным.

## 6. Анализ линейных моделей в контексте обратных задач

В рамках исследования обратных задач для нейронных дифференциальных уравнений в частных производных (nPDE) представляет интерес анализ линейных моделей, основанных на разложении решения по заданному базису функций. Рассмотрим подход, предложенный в работе [12], где в отличие от методов независимых компонент (ICA) используется векторное пространство функций  $\mathcal{H}$  с базисом  $\{\psi_i\}_{i=1}^{\infty}$ .

Пусть распределение источников  $s \in \mathcal{S}$  представляется в виде разложения по базису  $\{\psi_i\}$ :

$$s(\mathbf{r}, t) = \sum_{i=1}^{\infty} c_i \psi_i(\mathbf{r}, t), \quad (75)$$

где  $\{c_i\}_{i=1}^{\infty}$  — коэффициенты разложения. Тогда оператор прямой задачи  $T : \mathcal{S} \rightarrow \mathcal{F}$  действует на элемент  $s$  как:

$$Ts = \sum_{i=1}^{\infty} c_i T\psi_i, \quad (76)$$

а наблюдаемые данные  $d \in \mathcal{O}$  выражаются через оператор наблюдения  $C : \mathcal{F} \rightarrow \mathcal{O}$ :

$$d = CTs + \eta = \sum_{i=1}^{\infty} c_i CT\psi_i + \eta, \quad (77)$$

где  $\eta \in \mathcal{O}$  — аддитивный шум.

Введём матрицу Грама  $\mathbf{G} \in \mathbb{R}^{n \times n}$  с элементами  $G_{ij} = \langle CT\psi_i, CT\psi_j \rangle_{\mathcal{O}}$  и вектор  $\mathbf{b} \in \mathbb{R}^n$  с компонентами  $b_i = \langle d, CT\psi_i \rangle_{\mathcal{O}}$ . Тогда задача восстановления коэффициентов  $\{c_i\}$  сводится к решению системы линейных уравнений:

$$\mathbf{G}\mathbf{c} = \mathbf{b}, \quad (78)$$

где  $\mathbf{c} = (c_1, \dots, c_n)^{\top}$  — вектор коэффициентов.

Для обеспечения устойчивости решения вводится регуляризованный функционал:

$$J(\mathbf{c}) = \|\mathbf{G}\mathbf{c} - \mathbf{b}\|_2^2 + \alpha \mathbf{c}^{\top} \mathbf{T} \mathbf{c} + \beta \mathcal{R}_{TV}(\mathbf{c}), \quad (79)$$

где  $\mathbf{T}$  — матрица энергетического регуляризатора с элементами  $T_{ij} = \langle T\psi_i, T\psi_j \rangle_{\mathcal{F}}$ ,  $\mathcal{R}_{TV}(\mathbf{c})$  — дискретный аналог функционала полной вариации.

**Теорема 3** (Единственность решения линейной задачи). *Пусть матрица  $\mathbf{G} + \alpha \mathbf{T}$  положительно определена. Тогда регуляризованная задача имеет единственное решение  $\mathbf{c}^*$ , минимизирующее функционал  $J(\mathbf{c})$ .*



*Доказательство.* Матрица  $\mathbf{G} + \alpha \mathbf{T}$  положительно определена по условию, следовательно, функционал  $J(\mathbf{c})$  строго выпукл. Это гарантирует существование и единственность минимума  $\mathbf{c}^*$ .  $\square$

Таким образом, линейные модели, основанные на разложении по базису функций, предоставляют теоретически обоснованный подход к решению обратных задач, согласованный с предложенной в работе регуляризацией на основе энергетического функционала и полной вариации.

## 7. Вычислительный эксперимент

Для подтверждения теоретических результатов и оценки практической эффективности предложенного метода проводятся вычислительные эксперименты на реальных и синтетических данных. На реальных данных проверяется способность метода восстанавливать потенциал на датчиках. Синтетические данные используются для оценки точности восстановления распределения источников и потенциалов во внутренней области головы  $\Omega$ . В качестве реальных данных используются данные проекта Brunton et al. (`brunton_uw_bio`), в них представлены результаты измерений ЭЭГ сигнала в ходе выполнения различных когнитивных и моторных задач. Синтетические данные были сгенерированы для модели овальной головы с заданными дипольными источниками, что позволяет контролировать условия эксперимента и оценить точность восстановления.

### 7.1. Предобработка данных

Удаление высокочастотных и низкочастотных артефактов с использованием полосовых фильтров. Для данных ЭЭГ типичный диапазон фильтрации составлял 1–50 Гц. Приведение данных к единичному масштабу для устранения вариаций амплитуды сигнала. Приведение данных к единой частоте дискретизации для согласования с временной сеткой модели. Для уменьшения погрешности были также рассчитаны

## 8. Эксперименты

Цель эксперимента – оценить точность восстановления распределения источников  $s \in \mathcal{S}$  и полей  $y \in \mathcal{F}$  по наблюдаемым данным  $d \in \mathcal{O}$ , а также сравнить предложенный метод с существующими подходами, такими как LORETA. Для оценки качества восстановления использовались следующие метрики:

- **Sensor MSE**: среднеквадратичная ошибка восстановления потенциала на датчиках, расположенных на поверхности головы  $\Gamma = \partial\Omega$ .
- **Deep MSE**: среднеквадратичная ошибка восстановления полей и источников во внутренней области  $\Omega$ .

### 8.1. Эксперимент 1: Реальные данные проекта Brunton et al.

Модель обучалась для восстановления потенциала на датчиках и внутренних полей с использованием предложенной nPDE-архитектуры. Сравнения происходят на данных на датчиках. Так как в реальности невозможно получить точные значения полей и источников во внутренней области  $\Omega$ , оценка Deep MSE не проводится для реальных данных. Метод сравнивается с методои LORETA. Результаты эксперимента представлены в таблице 1.

| Метод              | Sensor MSE | Примечания |
|--------------------|------------|------------|
| Предложенный метод | —          |            |
| LORETA             | —          |            |

Таблица 1: Сравнение методов по реальным данным Brunton et al.

Результаты показывают, что предложенный метод обеспечивает сопоставимую точность восстановления потенциала на датчиках (Sensor MSE) по сравнению с LORETA. Но при этом позволяет контролировать свойства восстанавливаемых решений во внутренней области  $\Omega$  за счёт использования энергетической регуляризации  $\mathcal{R}_E(s)$  и TV-регуляризации  $\mathcal{R}_{TV}(s)$ , что является преимуществом по сравнению с LORETA, которая использует заранее заданные предположения об источниках как токах диполей.

### 8.2. Эксперимент 2: Синтетические данные

Во втором эксперименте использовались синтетические данные, сгенерированные для модели овальной головы с двумя независимыми источниками сигнала. Геометрия модели включала 16 датчиков, расположенных на поверхности  $\Gamma$ , и два источника во внутренней области  $\Omega$ . Частота дискретизации составляла 50 Гц. Визуализация конфигурации датчиков и источников приведена на рисунке 4.




Рис. 4: Визуализация синтетической модели головы с расположением датчиков и источников.

Синтетические данные позволяют оценить точность восстановления как на поверхности (Sensor MSE), так и во внутренней области (Deep MSE). Результаты эксперимента представлены в таблице 2.

| Метод              | Sensor MSE | Deep MSE |
|--------------------|------------|----------|
| Предложенный метод | —          | —        |
| LORETA             | —          | —        |

Таблица 2: Сравнение методов по синтетическим данным.

Из результатов следует, что

## 9. Результаты

Исходная задача решения уравнения  $Ks = d$  является плохо обусловленной задачей. Функционал  $J(s)$  с регуляризацией энергией  $\mathcal{R}_E(s)$  делает поставленную задачу корректной. На вычислительном эксперименте это подтверждается сопоставимой с методом LORETA ошибкой восстановления значения потенциалов на датчиках.

TV-регуляризация  $\mathcal{R}_{TV}(s)$  улучшает локализацию источников и подавляет нефизичные осцилляции. Это приводит к повышению точности восстановления во внутренней области  $\Omega$  на синтетических данных. Адаптивная настройка параметра  $\lambda_{\text{data}}$  позволяет балансировать между точностью аппроксимации данных и устойчивостью решения. Это особенно важно для реальных данных с высоким уровнем шума.

Предложенный метод лучше справляется с локализацией источников в условиях ограниченного числа датчиков и высокого уровня шума, что подтверждается результатами синтетического эксперимента. Он обеспечивает устойчивое и физически обоснованное восстановление распределения источников сигнала. Сочетание энергетической и TV-регуляризации позволяет преодолеть ограничения существующих подходов, таких как LORETA. Метод показывает более точные результаты в условиях ограниченного числа датчиков и высокого уровня шума.

Вычислительная сложность выше, чем у LORETA, так как используется итерационный алгоритм градиентного спуска для оптимизации функционала  $J(s)$  и обучается нейросеть для решения задачи PDE. В предложенном методе необходимо настраивать регуляризации  $\alpha$  и  $\beta$  для получения разряженных и низкоэнергетических решений. При этом должно быть заранее известно, что источники сигнала в мозге имеют низкую энергию и локализованы. Следствием этого решения априори смещены в сторону источников с меньшей энергией.

## 10. Заключение

Предложен метод решения обратной задачи, основанный на физико-информированном подходе. Метод априори не задает структуру решений, а выводит ее из физики задачи и параметров регуляризации разряженности и уровня энергии решений. Предложенный метод позволяет преодолеть ограничения классических подходов, таких как LORETA, и обеспечивает более точное восстановление источников сигнала в мозге.

Результаты работы подтверждают эффективность метода на синтетических и реальных данных. Метод демонстрирует устойчивость к шуму и высокую точность локализации источников.

При этом метод требует постоянного уточнения решения прямой задачи, что влияет на сходимость метода. Дальнейшие исследования будут направлены на поиск метода нахождения оператора решения прямой задачи без необходимости

его постоянного дообучения, что позволит обеспечить более быструю сходимость и улучшить качество восстановления источников сигнала.

## Список литературы

1. *Pascual-Marqui Roberto D.* Low Resolution Brain Electromagnetic Tomography (LORETA): The Technique, Its Validation, and Methods of Analysis // *Journal of Neurotherapy*. — 2001. — Vol. 4, no. 4. — Pp. 31–33.
2. Review on solving the inverse problem in EEG source analysis / Roberta Grech, Tracey Cassar, Joseph Muscat et al. // *Journal of NeuroEngineering and Rehabilitation*. — 2008. — ноябрь. — Vol. 5, no. 1.
3. *Weinstein David M., Zhukov Leonid, Johnson Chris R.* Lead Field Basis for FEM Source Localization. — 1999. — URL: <https://api.semanticscholar.org/CorpusID:11683372>.
4. Enhancing Brain Source Reconstruction by Initializing 3D Neural Networks with Physical Inverse Solutions / Marco Morik, Ali Hashemi, Klaus-Robert Müller et al. // *IEEE Transactions on Medical Imaging ( Volume: 45, Issue: 1, pp. 231 - 242, 2026)*. — 2024. — январь. — Vol. 45, no. 1. — Pp. 231–242.
5. Inverse EEG Problem, Minimization and Numerical Solutions / Georgina Paraskevopoulou, Athanassios S. Fokas, Antonios Charalambopoulos, Stavros Perantonis // *Chaos, Fractals and Complexity*. — Springer International Publishing, 2023. — Pp. 189–198.
6. Sparse wavelet-based solutions for the M/EEG inverse problem / Samy Mokhtari, Jean-Michel Badier, Christian G. Bénar, Bruno Torrèsani // *Sampling Theory and Applications (SampTA) 2023, Smita Krishnaswamy, Bastian Rieck, Ian Adelstein and Guy Wolf, Jul 2023, New Haven (Yale University), United States*. — 2023. — июнь.
7. *Zubov Kirill, McCarthy Zoe, Ma Yingbo et al.* NeuralPDE: Automating Physics-Informed Neural Networks (PINNs) with Error Approximations. — 2021.
8. *Billingsley Patrick.* Probability and Measure. — 3rd edition. — New York: John Wiley & Sons, 1995.
9. *van der Vaart Aad W.* Asymptotic Statistics. — Cambridge, UK: Cambridge University Press, 1998.
10. *Hoeffding Wassily.* Probability inequalities for sums of bounded random variables // *Journal of the American Statistical Association*. — 1963. — Vol. 58, no. 301. — Pp. 13–30.
11. *Bécache E., Dhia A. S. Bonnet-Ben, Legendre G.* Perfectly Matched Layers for the Convected Helmholtz Equation // *SIAM Journal on Numerical Analysis*. — 2004. — январь. — Vol. 42, no. 1. — Pp. 409–433.

12. Functional principal component analysis for incomplete space–time data / Alessandro Palummo, Eleonora Arnone, Luca Formaggia, Laura M. Sangalli // *Environmental and Ecological Statistics*. — 2024. — март. — Vol. 31, no. 2. — Pp. 555–582.