

Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский физико-технический институт
(национальный исследовательский университет)»
Физтех-школа прикладной математики и информатики
Кафедра интеллектуальных систем

Терентьев Александр Александрович

**ОБРАТНЫЕ ЗАДАЧИ В МОДЕЛИРОВАНИИ
НЕЙРОННЫХ ДИФФЕРЕНЦИАЛЬНЫХ УРАВНЕНИЙ
В ЧАСТНЫХ ПРОИЗВОДНЫХ**

09.04.01 — Информатика и вычислительная техника

Выпускная квалификационная работа магистра

Научный руководитель:
Стрижов Вадим Викторович,
д-р физ.-мат. наук

Москва — 2026

Аннотация

В задачах ЭЭГ трудность вызывает получение точного сигнала от головного мозга. Исследователи встречаются со следующими проблемами. Высокая чувствительность прибора к движениям и тремору, обусловленному психоэмоциональным напряжением пациента, вызывает помехи в работе, что может затруднить диагностику. Такие изменения называются артефактами движения. А если встраивать датчики напрямую в кору мозга, то они уже сами начинают влиять на его работу, а через некоторое время приходят в негодность из-за перестройки мозга вокруг них. Поэтому стоит задача точного определения восстановления местоположения источников сигнала, при условии высокого уровня шума для работы с этими источниками в медицинских целях. Целью работы является предложить метод решения восстановления источников сигнала ЭЭГ и уменьшения уровня шума в их определении. Предлагается использовать физико-информированный подход в восстановлении, использующийся в задачах восстановления временных рядов, вносящий априорные знания о модели для уменьшения уровня шума от данных.

Содержание

1	Введение	5
1.1	Определение задачи обратного восстановления ЭЭГ	5
2	Регуляризация обратной задачи через энергию поля	7
3	Физико-информированный подход	9
4	Операторная постановка и свойства операторов	10
4.1	Оператор решения прямой задачи T	10
4.2	Оператор наблюдения C	11
4.3	Композиция операторов $K = C \circ T$	11
4.4	Аппроксимация энергетической регуляризации	11
5	Теоретическая основа регуляризации через энергию	13
5.1	Постановка обратной задачи в операторной форме для конечного числа источников и датчиков	13
5.2	Пример вырожденной геометрии и проблема неединственности . .	13
5.3	Регуляризованный функционал	14
5.3.1	Явное решение через минимизацию функционала	14
5.4	Аналитическое решение	15
5.4.1	Аналитическое решение с регуляризацией	16
5.5	Общая вариационная постановка	18
5.6	Единственность решения общей задачи	18
5.7	Анализ аппроксимации оператора прямой задачи	20
5.8	Схема решения обратной задачи	23
5.8.1	Аппроксимация оператора прямой задачи и сходимость решений	23
5.8.2	Энергетическая регуляризация и ее свойства	24
5.8.3	Структурная регуляризация	24
5.8.4	Метод минимизации регуляризованного функционала . . .	25
5.8.5	Адаптивная регуляризация	25
5.9	Граничные условия для прямой задачи	25
5.9.1	Свойства предложенного решения	26
6	Анализ линейных моделей в контексте обратных задач	27
7	Вычислительный эксперимент	29
8	Эксперименты	30
8.1	Эксперимент 1: Реальные данные проекта Brunton et al.	30
8.2	Эксперимент 2: Синтетические данные	30

9	Результаты	32
10	Заключение	32
	Список литературы	33

1. Введение

Обратная задача ЭЭГ имеет фундаментальное значение для исследования активности мозга, поскольку она позволяет получить представление о пространственной и временной структуре распределения источников сигнала в мозге при выполнении различных когнитивных и моторных задач. Это позволяет определять аномалии в активности мозга и их причины, что способствует пониманию внутренней работы мозга и выявлению областей с аномалиями проводимости, которые могут указывать на поврежденную ткань [1]. Обратная задача ЭЭГ является плохо обусловленной, поэтому у нее не существует единственного решения, обусловленного ограниченным числом наблюдений на поверхности головы.

Для восстановления приближенного решения необходимо задать модель источников и регуляризирующий функционал. В работах MNE [2] и томографии электрической активности низкого разрешения (LORETA) [3] рассматриваются линейные источники и квадратичная регуляризация, учитывающие взаимосвязь между источниками тока и измеренными потенциалами в предположении квазистатического приближения. Есть нейросетевые подходы, решающие псевдообратную задачу, но не учитывающие физику электромагнитного сигнала [4]. Целью данной работы является предложить метод регуляризации для обратной задачи pPDE, основанной на максимально общей физической модели описания источников поля. Модель источников должна быть достаточно гибкой, чтобы описывать широкий спектр возможных источников сигнала в мозге, включая как локализованные, так и распределенные источники. При этом регуляризация должна быть физически обоснованной, учитывать электромагнитную природу задачи и обеспечивать устойчивость решения [5]. В большинстве работ используется предположение о квазистатичности процессов, происходящих в мозге. В общем случае это неверно. Для моделирования источников коротких сигналов в мозге необходимо учитывать зависимость поля от скорости изменения источников сигнала. Целью работы является предложение такой модели, которая автоматически учитывает зависимость поля от скорости изменения источников сигнала, тем самым описывая эффект индукции от резкого изменения токов.

1.1. Определение задачи обратного восстановления ЭЭГ

В общем случае обратная задача ЭЭГ формулируется как задача восстановления непрерывного распределения источников $s \in \mathcal{S}$ по конечному набору наблюдений $d \in \mathcal{O}$. Введем три функциональных пространства.

Пространство источников $\mathcal{S}$ – гильбертово пространство распределений поляризации $\mathbf{P}(\mathbf{r}, t)$ в области $\Omega \subset \mathbb{R}^3$. Пространство полей $\mathcal{F}$ – гильбертово пространство потенциалов $\phi(\mathbf{r}, t)$ и $\mathbf{A}(\mathbf{r}, t)$. Пространство наблюдений $\mathcal{O} = \mathbb{R}^n$ – евклидово пространство измерений на n датчиках.

Пусть $T : \mathcal{S} \rightarrow \mathcal{F}$ – оператор прямой задачи, ставящий в соответствие

распределению источников поле, удовлетворяющее уравнениям Максвелла в области Ω . Пусть $C : \mathcal{F} \rightarrow \mathcal{O}$ – оператор наблюдения, проецирующий поле на значения, измеряемые датчиками на границе $\Gamma = \partial\Omega$. Тогда оператор наблюдаемой прямой задачи определяется как композиция:

$$K = C \circ T : \mathcal{S} \rightarrow \mathcal{O}. \quad (1)$$

Наблюдаемые данные d представляются в виде:

$$d = Ks + \eta, \quad (2)$$

где $\eta \in \mathcal{O}$ – аддитивный шум. Требуется восстановить источник $s \in \mathcal{S}$ по данным $d \in \mathcal{O}$. Оператор K вырожден, так как множество источников, порождающих одинаковые наблюдения, бесконечно. Для корректной постановки задачи вводится регуляризация, обеспечивающая устойчивость и физическую обоснованность решения.

В задаче ЭЭГ T является оператором решения уравнений Максвелла, который отображает распределение источников в электромагнитное поле. Из принципа суперпозиции и линейности уравнений Максвелла следует, что T – линейный оператор. Оператор C проецирует поле на значения, измеряемые датчиками. Поле $y = Ts$ в модели является непрерывным по координатам




Рис. 1: Поверхность головы Γ




Рис. 2: Разрез объема Ω

(x, y, z, t) в области головы Ω [Рисунок 2]. Однако наблюдения d – это дискретные значения поля на датчиках, расположенных на поверхности головы Γ [Рисунок 1]. Поэтому оператор C – это дискретизирующий оператор, который отображает непрерывное поле в конечный набор значений на датчиках. В результате оператор $K = CT$ является композицией непрерывного оператора T и дискретизирующего оператора C , что делает его вырожденным [5].

2. Регуляризация обратной задачи через энергию поля

Из линейности оператора следует, что множество решений прямой задачи для данных d задается

$$\mathcal{X}(d) = \{x \in x_0 + \ker(K)\}, Kx_0 = d.$$

Поэтому в качестве регуляризации предлагается взять квадратичный функционал, который моделирует энергию взаимодействия электромагнитного поля с источниками через положительно определенный оператор потенциала T :

$$E[f] = \langle Tf, f \rangle_{\mathcal{S}}, \quad (3)$$

где Tf – поле, генерируемое источниками, а f – сами источники.

Энергия поля задает слишком большую стоимость для решений, которые создают сильные поля на датчиках, что соответствует физической интуиции о том, что источники с высокой энергией менее вероятны. Но при этом она поощряет некомпактные решения, которые не соответствуют реальным источникам в мозге. Поэтому в качестве дополнительного регуляризатора предлагается использовать функционал полной вариации $\text{TV}(s)$ [6], который поощряет локализованные и кусочно-постоянные решения.

Пусть $\mathcal{O}$ – гильбертово пространство наблюдений, $\mathcal{F}$ – гильбертово пространство полей, а $\mathcal{S}$ – гильбертово пространство источников. Тогда задача восстановления источников формулируется как оптимизация функционала

$$J(s) = \|Ks - d\|_{\mathcal{O}}^2 + \alpha \langle Ts, s \rangle_{\mathcal{S}} + \beta \text{TV}(s) \rightarrow \min_{s \in \mathcal{S}}, \quad (4)$$

где первый член отвечает за соответствие данным, второй – за энергию взаимодействия поля с источниками и устойчивость модели, а третий – за пространственную структурированность источника, α – регуляризация высокоэнергетических источников, β – регуляризация некомпактных источников. В случае, если решение s представлено через нейросеть s_{θ} , эта постановка сводится к оптимизации по параметрам θ .

На рисунке 3 показана упрощенная схема: оператор D восстанавливает параметры источников из данных, а G воспроизводит предсказанное поле. В оператор-терминах D задает обратное отображение из $\mathcal{O}$ в $\mathcal{S}$, а G реализует прямой оператор $K = CT$.

Таким образом, мы формулируем задачу nPDE как поиск решения $\hat{s}$ функционала (4) в пространстве $\mathcal{S}$. Оператор K имеет ненулевое ядро, что приводит к бесконечному множеству решений, которые соответствуют данным d , а единственность достигается за счет регуляризаторов T и TV [4].

$$\chi_i : (N_x \times N_y \times N_z \times T) \xrightarrow{D(\hat{s}|X, \mathcal{D})} \mathcal{S} \xrightarrow{G(\hat{X}|X(t), \hat{s}, \mathcal{D})} \hat{\mathbf{X}}$$

Рис. 3: Модель сигнала ЭЭГ

Формально пространственно-временной ряд χ можно записать как ряд поля $E(\mathbf{r})_t$. Таким образом задача состоит в нахождении источников поля E .

В работе предлагается использовать уравнения в частных производных для восстановления динамики поля. В общем виде это можно записать так

$$A\left(s, r, t, E, \frac{\partial E}{\partial \mathbf{r}}, \frac{\partial E}{\partial t}, \dots\right) = 0.$$

3. Физико-информированный подход

В работе предлагается взять представление уравнений Максвелла через потенциалы ϕ , A и поляризацию P . Нейросеть аппроксимирует в каждой точке (x, y, z, t) семь компонент:

$$\phi, \mathbf{A} = (A_x, A_y, A_z), \mathbf{P} = (P_x, P_y, P_z).$$

Поляризация $\mathbf{P}$ определяет источники, потенциалы ϕ и $\mathbf{A}$ – поля. Плотность заряда и плотность тока выражаются через поляризацию:

$$\rho = -\operatorname{div} \mathbf{P}, \quad \mathbf{j} = \frac{\partial \mathbf{P}}{\partial t}. \quad (5)$$

Электрическое поле $\mathbf{E}$ и магнитное поле $\mathbf{B}$ задаются через потенциалы:

$$\mathbf{E} = -\nabla\phi - \frac{\partial \mathbf{A}}{\partial t}, \quad \mathbf{B} = \nabla \times \mathbf{A}. \quad (6)$$

Параметризация через потенциалы и поляризацию минимизирует число степеней свободы и соответствует дипольной природе источников сигнала в мозге.

Уравнения Максвелла в выбранной постановке принимают вид волновых уравнений для потенциалов:

$$\square\phi = 4\pi\nabla \cdot \mathbf{P}, \quad (7)$$

$$\square\mathbf{A} = -\frac{4\pi}{c} \frac{\partial \mathbf{P}}{\partial t}, \quad (8)$$

где $\square = \nabla^2 - \frac{1}{c^2} \frac{\partial^2}{\partial t^2}$ – оператор Д’Аламбера. Калибровка Лоренца:

$$\nabla \cdot \mathbf{A} + \frac{1}{c} \frac{\partial \phi}{\partial t} = 0. \quad (9)$$

Традиционная формулировка через поля $\mathbf{E}$, $\mathbf{B}$ и плотности ρ , $\mathbf{j}$ требует большего числа компонент и не обеспечивает естественной структуры поляризации. Решения уравнений Максвелла ищутся с помощью nPDE [7].

4. Операторная постановка и свойства операторов

4.1. Оператор решения прямой задачи T

Оператор $T : \mathcal{S} \rightarrow \mathcal{F}$ определяется как $T\mathbf{P} = (\phi, \mathbf{A})$, где ϕ и $\mathbf{A}$ — решения волновых уравнений:

Линейность оператора T следует из линейности оператора Д'Аламбера $\square$ и линейности граничных условий. Для любых $\mathbf{P}_1, \mathbf{P}_2 \in \mathcal{S}$ и скаляров $\alpha, \beta \in \mathbb{R}$ выполняется:

$$T(\alpha\mathbf{P}_1 + \beta\mathbf{P}_2) = \alpha T\mathbf{P}_1 + \beta T\mathbf{P}_2. \quad (10)$$

Ограниченность оператора T доказывается с использованием энергетических оценок для волновых уравнений. Рассмотрим норму решения $(\phi, \mathbf{A}) = T\mathbf{P}$ в пространстве $\mathcal{F}$:

$$\|(\phi, \mathbf{A})\|_{\mathcal{F}}^2 = \int_{\Omega} \int_0^T \left(|\phi|^2 + \|\nabla\phi\|^2 + \|\mathbf{A}\|^2 + \|\nabla \times \mathbf{A}\|^2 + \left| \frac{\partial \mathbf{A}}{\partial t} \right|^2 \right) dt d\mathbf{r}. \quad (11)$$

Для волнового уравнения $\square\phi = 4\pi\nabla \cdot \mathbf{P}$ с нулевыми начальными и граничными условиями справедлива оценка:

$$\|\phi\|_{H^1(\Omega \times [0, T])} \leq C_1 \|\nabla \cdot \mathbf{P}\|_{L^2(\Omega \times [0, T])}, \quad (12)$$

где $C_1 > 0$ — константа, зависящая от области Ω и временного интервала $[0, T]$, H^1 — пространство Соболева. Аналогичная оценка справедлива для $\mathbf{A}$:

$$\|\mathbf{A}\|_{H^1(\Omega \times [0, T])} \leq C_2 \left\| \frac{\partial \mathbf{P}}{\partial t} \right\|_{L^2(\Omega \times [0, T])}. \quad (13)$$

Так как $\|\nabla \cdot \mathbf{P}\|_{L^2} \leq \|\mathbf{P}\|_{H^1}$ и $\left\| \frac{\partial \mathbf{P}}{\partial t} \right\|_{L^2} \leq \|\mathbf{P}\|_{H^1}$, то:

$$\|T\mathbf{P}\|_{\mathcal{F}} \leq C_T \|\mathbf{P}\|_{\mathcal{S}}, \quad (14)$$

где $C_T = \max(C_1, C_2)$ — константа, не зависящая от $\mathbf{P}$.

Положительная определенность оператора T обусловлена физическим смыслом квадратичной формы $\langle T\mathbf{P}, \mathbf{P} \rangle_{\mathcal{S}}$, соответствующей энергии взаимодействия поля с источниками:

$$\langle T\mathbf{P}, \mathbf{P} \rangle_{\mathcal{S}} = \int_{\Omega} (\rho\phi + \mathbf{A} \cdot \mathbf{j}) d\mathbf{r} > 0, \quad \forall \mathbf{P} \neq 0. \quad (15)$$

4.2. Оператор наблюдения C

Оператор $C : \mathcal{F} \rightarrow \mathcal{O}$ определяется как:

$$C(\phi, \mathbf{A}) = (\phi(\mathbf{r}_1, t), \phi(\mathbf{r}_2, t), \dots, \phi(\mathbf{r}_n, t))^\top, \quad (16)$$

где $\mathbf{r}_i \in \Gamma = \partial\Omega$ – координаты датчиков. Оператор C линейен и ограничен.

4.3. Композиция операторов $K = C \circ T$

Оператор $K : \mathcal{S} \rightarrow \mathcal{O}$ определяется как $K\mathbf{P} = C(T\mathbf{P})$. Оператор K линейен, ограничен, и его ранг не превышает $n = \dim \mathcal{O}$.

4.4. Аппроксимация энергетической регуляризации

В работе в качестве регуляризации предлагается использовать энергию электрического поля, формально задаваемую как

$$E = \int_{\Omega} \phi(r) \rho(r) dr.$$

Ее главным вычислительным недостатком является необходимость численного интегрирования по объему Ω на каждом шаге оптимизации и нахождение решения nPDE для нее. Так как на каждом шаге оптимизации мы не можем гарантировать, что решение nPDE будет найдено с заданной точностью, то численное интегрирование может быть неточным и дорогим. Поэтому предлагается использовать стохастическую аппроксимацию Монте-Карло для оценки этого интеграла.

Лемма 1 (Эквивалентность энергии и Монте-Карло оценки через произведение $\phi\rho$). Пусть $\Omega \subset \mathbb{R}^d$ – измеримое множество с конечным объемом $|\Omega| > 0$. Пусть функции $\phi, \rho : \Omega \rightarrow \mathbb{R}$ такие, что $\phi\rho \in L^1(\Omega)$. Пусть $r_1, \dots, r_K$ – i.i.d. точки, выбранные по вероятностной мере μ на Ω с плотностью $p(r) > 0$ почти всюду (в частности, допускается равномерная выборка $p \equiv 1/|\Omega|$). Определим

$$E := \int_{\Omega} \phi(r) \rho(r) dr, \quad \hat{E}_K := \frac{1}{K} \sum_{i=1}^K w(r_i) \phi(r_i) \rho(r_i), \quad w(r) = \frac{1}{p(r)}.$$

Тогда выполняются следующие утверждения:

1. (Несмещенность) $\mathbb{E}[\hat{E}_K] = E$.
2. (Сходимость) $\hat{E}_K \xrightarrow{a.s.} E$ при $K \rightarrow \infty$; более того, при $\mathbb{E}[|w\phi\rho|] < \infty$ имеем $\hat{E}_K \rightarrow E$ в L^1 .

3. (Случайная погрешность) Если дополнительно $w\phi\rho \in L^2(\mu)$, то по центральной предельной теореме

$$\sqrt{K}(\hat{E}_K - E) \xrightarrow{d} \mathcal{N}(0, \sigma^2), \quad \sigma^2 = \text{Var}_\mu(w\phi\rho).$$

Следовательно, типичный масштаб ошибки равен $O_p(1/\sqrt{K})$.

4. (Оценка хвостов) Если $|w(r)\phi(r)\rho(r)| \leq M$ почти наверное, то по неравенству Хеффдинга для суммы независимых ограниченных слагаемых

$$\mathbb{P}(|\hat{E}_K - E| \geq \varepsilon) \leq 2 \exp\left(-\frac{2K\varepsilon^2}{M^2}\right).$$

Доказательство. Пункт 1:

$$\mathbb{E}[\hat{E}_K] = \mathbb{E}\left[\frac{1}{K} \sum_{i=1}^K w(r_i)\phi(r_i)\rho(r_i)\right] = \mathbb{E}[w(r)\phi(r)\rho(r)] = \int_{\Omega} \phi(r)\rho(r) dr = E,$$

где на втором шаге использована линейность матожидания и идентичность распределения сэмплов (см. [8]).

Пункт 2: из предположения $\mathbb{E}[|w\phi\rho|] < \infty$ и закона больших чисел для i.i.d. последовательностей следует сходимость почти наверное $\hat{E}_K \rightarrow E$ и сходимость в среднем (при дополнительных условиях) — в L^1 (см. [8]).

Пункт 3: при конечной дисперсии $\text{Var}_\mu(w\phi\rho) = \sigma^2 < \infty$ применима центральная предельная теорема, которая дает сходимость распределений к нормальной с указанной дисперсией (см. [9]).

Пункт 4: если слагаемые ограничены по модулю M , то применима версия неравенства Хеффдинга для сумм i.i.d. ограниченных величин, откуда и следует указанная оценка (см. [10]). $\square$

Для фиксированного множителя регуляризации $\lambda > 0$ замена непрерывного регуляризатора λE на дискретную версию $\lambda \hat{E}_K$ дает состоятельную аппроксимацию: $\hat{E}_K \rightarrow E$ при $K \rightarrow \infty$, а погрешность имеет порядок $O_p(1/\sqrt{K})$.

Замечание 1. Аппроксимация вида $\frac{1}{K} \sum_i \phi(r_i)\rho(r_i)$ (для $p \equiv 1/|\Omega|$) дает простую и эффективную реализацию регуляризатора во время стохастического градиентного спуска и уменьшает вычислительные затраты по сравнению с оценкой полной энергии по сетке.

5. Теоретическая основа регуляризации через энергию

5.1. Постановка обратной задачи в операторной форме для конечного числа источников и датчиков

Пусть $\Omega \subset \mathbb{R}^3$ – область, в которой заданы m точечных источников с комплексными амплитудами $f_1, f_2, \dots, f_m \in \mathbb{C}$ в точках $s_1, s_2, \dots, s_m \in \Omega$. На фиксированной частоте $\omega > 0$ измеряется одна компонента поля E_z в двух точках $r_1, r_2, \dots, r_n \notin \{s_1, s_2, \dots, s_m\}$. В дискретном приближении значение потенциала от источника описывается функцией $G(r, s; \omega)$:

$$d_i = G(r_i, s_1; \omega)f_1 + G(r_i, s_2; \omega)f_2 + \dots + G(r_i, s_m; \omega)f_m, \quad i = 1, 2, \dots, n. \quad (17)$$

Обозначим

$$f = \begin{pmatrix} f_1 \\ f_2 \\ \vdots \\ f_m \end{pmatrix}, \quad d = \begin{pmatrix} d_1 \\ d_2 \\ \vdots \\ d_n \end{pmatrix}, \quad K = \begin{pmatrix} G(r_1, s_1; \omega) & G(r_1, s_2; \omega) & \dots & G(r_1, s_m; \omega) \\ G(r_2, s_1; \omega) & G(r_2, s_2; \omega) & \dots & G(r_2, s_m; \omega) \\ \vdots & \vdots & \ddots & \vdots \\ G(r_n, s_1; \omega) & G(r_n, s_2; \omega) & \dots & G(r_n, s_m; \omega) \end{pmatrix}. \quad (18)$$

Тогда прямая задача записывается компактно как

$$d = Kf. \quad (19)$$

Тогда прямая задача записывается компактно как

$$d = Kf. \quad (20)$$

Оператор K является дискретной версией композиции $K = CT$, где T – оператор решения уравнения Максвелла, а C – оператор наблюдений на датчиках.

5.2. Пример вырожденной геометрии и проблема неединственности

Рассмотрим геометрию задачи для трех источников, при которой функции Грина для трех источников в двух точках наблюдения задаются следующей матрицей:

$$G(r_1, s_1) = g_{11}, \quad G(r_2, s_1) = g_{21}, \quad G(r_1, s_2) = g_{12}, \quad G(r_2, s_2) = g_{22}, \quad G(r_1, s_3) = g_{13}, \quad G(r_2, s_3) = g_{23}. \quad (21)$$

Тогда

$$K = \begin{pmatrix} g_{11} & g_{12} & g_{13} \\ g_{21} & g_{22} & g_{23} \end{pmatrix}, \quad \text{rank}(K) = 2. \quad (22)$$

Множество решений прямой задачи определяется в случае двух источников и двух датчиков как

$$\mathcal{S}(d) = \{f \in \mathbb{C}^2 : f_3 = \frac{f_1(g_{11}d_2 - g_{21}d_1) + f_2(g_{12}d_2 - g_{22}d_1)}{g_{13}d_2 - g_{23}d_1}\}. \quad (23)$$

Это аффинное подпространство размерности один, и невырожденных решений бесконечно много. Формально, $\ker K = \{(x, y, z) : ax + by + cz = 0\}$, и к любому решению можно прибавить произвольный элемент ядра, не изменяя данные.

5.3. Регуляризованный функционал

Для устранения неединственности вводим регуляризованный функционал

$$J(f) = \|Kf - d\|_2^2 + \alpha \frac{1}{2} (Tf, f)_2^2 + \beta (|f_1 - f_2| + |f_1 - f_3| + |f_2 - f_3|), \quad \alpha > 0, \beta \geq 0. \quad (24)$$

$\|Kf - d\|_2^2$ – это невязка между данными и оценкой потенциала моделью. $(Tf, f)_2^2$ – регуляризация энергии поля. В частотной области оно эквивалентно квадратичному штрафу за амплитуду наблюдаемого поля. Третье слагаемое представляет собой дискретный вариант полной вариации, поощряющий схожесть точечных источников и препятствующий неструктурированному разбросу амплитуд.

Подставляя матрицу (22) и вводя вектор наблюдаемого поля

$$s = Kf \in \mathbb{R}^2, \quad (25)$$

функционал (24) переписывается как

$$J(f) = \|s - d\|_2^2 + \frac{\alpha}{2} \|s\|_2^2 + \beta (|f_1 - f_2| + |f_1 - f_3| + |f_2 - f_3|), \quad s = Kf. \quad (26)$$

5.3.1. Явное решение через минимизацию функционала

Минимизируем функционал (24) при $\beta = 0$. Энергия взаимодействия представляет произведение источника на потенциал, генерируемый этим источником. В дискретном случае это скалярное произведение $f^T T^T f$, где T – оператор потенциала:

$$J(f) = \|Kf - d\|_2^2 + \frac{\alpha}{2} f^T T^T f. \quad (27)$$

Раскроем функционал:

$$J(f) = f^T K^T K f - 2f^T K^T d + \|d\|_2^2 + \frac{\alpha}{2} f^T T^T f. \quad (28)$$

Вычислим градиент по f :

$$\nabla_f J = 2K^T K f - 2K^T d + \alpha T^T f. \quad (29)$$

Приравняв к нулю, получаем нормальную систему уравнений:

$$(2K^T K + \alpha T^T) f^* = 2K^T d. \quad (30)$$

Матрица $(2K^T K + \alpha T^T)$ размера (3×3) является положительно определенной при $\alpha > 0$, поскольку $K^T K$ положительно полуопределена (имеет ранг 2), а T^T положительно определена, так как энергия поля $E[f] = f^T T^T f > 0$ при $f \neq 0$. Таким образом, система имеет единственное решение f^* .

Сравнение с исходным СЛАУ: исходная система $Kf = d$ при $\text{rank}(K) = 2$ имеет бесконечное множество решений, образующих одномерное аффинное подпространство:

$$\mathcal{F}_{\text{original}} = \{f \in \mathbb{R}^3 : Kf = d\}. \quad (31)$$

Регуляризованная задача с энергетическим штрафом $\alpha f^T T^T f > 0$ имеет единственное решение f^* , полученное как минимум функционала $J(f)$. Это решение, как правило, не принадлежит исходному множеству решений $\mathcal{F}_{\text{original}}$ при $\alpha > 0$, так как энергетический штраф переводит оптимум в точку, которая генерирует наблюдаемое поле с иной амплитудой.

При $\alpha = 0$ (без энергетической регуляризации) система (30) имеет нулевой правый оператор $(2K^T K)$, и множество решений совпадает с исходным: $\mathcal{F}^* = \mathcal{F}_{\text{original}}$.

5.4. Аналитическое решение

Рассмотрим частный случай для симметричной матрицы T . Пусть матрица T симметрична, тогда искомый вектор имеет структуру:

$$f_1 = f_2 = x, \quad f_3 = 0.$$

Подставим этот вектор в уравнение для стационарной точки функционала:

$$(2K^T K + \alpha T^T) \begin{pmatrix} x \\ x \\ 0 \end{pmatrix} = 2K^T d.$$

Пусть матрица K имеет строки (g_{11}, g_{12}, g_{13}) и (g_{21}, g_{22}, g_{23}) . Тогда

$$K \begin{pmatrix} x \\ x \\ 0 \end{pmatrix} = \begin{pmatrix} (g_{11} + g_{12})x \\ (g_{21} + g_{22})x \end{pmatrix}.$$

Отсюда

$$K^T K \begin{pmatrix} x \\ x \\ 0 \end{pmatrix} = \begin{pmatrix} g_{11}(g_{11} + g_{12}) + g_{21}(g_{21} + g_{22}) \\ g_{12}(g_{11} + g_{12}) + g_{22}(g_{21} + g_{22}) \\ 0 \end{pmatrix} x.$$

Правая часть:

$$K^T d = \begin{pmatrix} g_{11}d_1 + g_{21}d_2 \\ g_{12}d_1 + g_{22}d_2 \\ g_{13}d_1 + g_{23}d_2 \end{pmatrix}.$$

Так как третья компонента решения равна нулю, третье уравнение не участвует в определении x . Получаем систему:

$$2A_1x + \alpha(T^T)_{11}x = 2B_1,$$

$$2A_2x + \alpha(T^T)_{22}x = 2B_2,$$

где

$$A_1 = g_{11}(g_{11} + g_{12}) + g_{21}(g_{21} + g_{22}), \quad A_2 = g_{12}(g_{11} + g_{12}) + g_{22}(g_{21} + g_{22}),$$

$$B_1 = g_{11}d_1 + g_{21}d_2, \quad B_2 = g_{12}d_1 + g_{22}d_2.$$

Если матрица T симметрична и действует одинаково на первые две компоненты, то

$$(T^T)_{11} = (T^T)_{22} = \lambda_s.$$

Тогда обе строки дают одно и то же уравнение, и решение имеет вид:

$$x = \frac{B_1 + B_2}{A_1 + A_2 + \frac{\alpha}{2}\lambda_s}.$$

Подставляя выражения для A_i и B_i , получаем окончательную формулу:

$$x = \frac{g_{11}d_1 + g_{21}d_2 + g_{12}d_1 + g_{22}d_2}{g_{11}(g_{11} + g_{12}) + g_{21}(g_{21} + g_{22}) + g_{12}(g_{11} + g_{12}) + g_{22}(g_{21} + g_{22}) + \frac{\alpha}{2}\lambda_s}.$$

При увеличении параметра α знаменатель возрастает, и амплитуда решения x монотонно уменьшается. В случае $\alpha = 0$ получается решение исходной плохо обусловленной задачи.

5.4.1. Аналитическое решение с регуляризацией

Рассмотрим частный случай для трех источников с регуляризацией

$$J(f) = \|Kf - d\|_2^2 + \frac{\alpha}{2}f^T T^T f + \beta(|f_1 - f_2| + |f_1 - f_3| + |f_2 - f_3|). \quad (32)$$

TV-регуляризация вводит кусочно-гладкую структуру: она штрафует различия между компонентами источника, поощряя их группировку в однородные блоки.

Для симметричного случая $f_1 = f_2 = x$ и $f_3 = 0$ имеем:

$$\text{TV}(f) = |x - x| + |x - 0| + |x - 0| = 2|x|. \quad (33)$$

Подставляя в функционал и опуская константы:

$$J(x) = [(g_{11} + g_{12})x - d_1]^2 + [(g_{21} + g_{22})x - d_2]^2 + \frac{\alpha}{2}\lambda x^2 + 2\beta|x|, \quad (34)$$

где λ – энергетический параметр из оператора T^T (зависит от геометрии).

Раскроем квадраты и соберем коэффициенты:

$$J(x) = Ax^2 - 2Bx + 2\beta|x| + \text{const}, \quad (35)$$

где

$$A = (g_{11} + g_{12})^2 + (g_{21} + g_{22})^2 + \frac{\alpha}{2}\lambda, \quad B = (g_{11} + g_{12})d_1 + (g_{21} + g_{22})d_2. \quad (36)$$

Случай 1: $x > 0$. Функционал становится:

$$J(x) = Ax^2 - (2B - 2\beta)x + \text{const}. \quad (37)$$

Условие минимума:

$$\frac{dJ}{dx} = 2Ax - (2B - 2\beta) = 0 \quad \Rightarrow \quad x^* = \frac{B - \beta}{A}. \quad (38)$$

Это решение валидно, если $x^* > 0$, т.е. $B > \beta$.

Случай 2: $x < 0$. Из симметрии получаем $x^* = -\frac{B+\beta}{A}$, что требует $B < -\beta$. Предполагается, что $B > 0$, поэтому неравенство выполнено всегда.

Случай 3: $x = 0$. Функция $|x|$ не дифференцируема в нуле. Используя субдифференциал:

$$0 \in \partial J(0) \quad \Leftrightarrow \quad 0 \in [-2B - 2\beta, -2B + 2\beta]. \quad (39)$$

Это верно, если $B \leq \beta$.

Итоговое решение при $\beta > 0$:

$$f_1^* = f_2^* = \begin{cases} \frac{B-\beta}{A}, & \text{если } B > \beta, \\ 0, & \text{если } B \leq \beta, \end{cases} \quad f_3^* = 0. \quad (40)$$

Где:

$$A = (g_{11} + g_{12})^2 + (g_{21} + g_{22})^2 + \frac{\alpha}{2}\lambda_s, \quad B = (g_{11} + g_{12})d_1 + (g_{21} + g_{22})d_2. \quad (41)$$

Физическая интерпретация: Регуляризация источников увеличивается при увеличении коэффициента β . Коэффициент определяет, при каких значениях источники начинают зануляться. Данный коэффициент позволяет контролировать точечный источник. Не допускает уход источников на границу области, что предполагает решение с минимальной энергией.

5.5. Общая вариационная постановка

Пусть $\mathcal{S}, \mathcal{F}, \mathcal{O}$ – гильбертовы пространства, $T : \mathcal{S} \rightarrow \mathcal{F}$ – линейный оператор решения прямой задачи, получения распределения потенциалов по распределению источников, $C : \mathcal{F} \rightarrow \mathcal{O}$ – линейный оператор наблюдения, и $K = CT : \mathcal{S} \rightarrow \mathcal{O}$ – линейный оператор наблюдения прямой задачи. Пусть $T : \mathcal{S} \rightarrow \mathcal{F}$ – положительно определенный оператор. Пусть $\text{TV}(s)$ – функционал полной вариации функции в пространстве источников. Тогда функционал обратной задачи определяется как:

$$J(s) = \|Ks - d\|_{\mathcal{O}}^2 + \alpha \frac{1}{2} \langle Ts, s \rangle_{\mathcal{S}} + \beta \text{TV}(s), \quad s \in \mathcal{S}. \quad (42)$$

$\|Kf - d\|_{\mathcal{O}}^2$ обеспечивает соответствие данным; $\langle Tf, f \rangle_{\mathcal{S}}$ моделирует энергию взаимодействия поля с источниками; $\text{TV}(f)$ вводит структурную регуляризацию, поощряя локализованные и кусочно-постоянные решения.

5.6. Единственность решения общей задачи

Лемма 2. Пусть $\mathcal{S}, \mathcal{F}, \mathcal{O}$ – гильбертовы пространства, $T : \mathcal{S} \rightarrow \mathcal{F}$ и $C : \mathcal{F} \rightarrow \mathcal{O}$ – ограниченные линейные операторы, $K = C \circ T : \mathcal{S} \rightarrow \mathcal{O}$ – их композиция. Если T положительно определен на $\mathcal{S}$ (то есть $\langle Tf, f \rangle_{\mathcal{S}} > 0$ для всех $f \neq 0$), то оператор $A = K^*K + \alpha T$ (при $\alpha > 0$) является положительно определенным и обратимым.

Доказательство леммы 2. Для любого $f \neq 0 \in \mathcal{S}$ имеем:

$$\langle Af, f \rangle_{\mathcal{S}} = \langle K^*Kf, f \rangle_{\mathcal{S}} + \alpha \langle Tf, f \rangle_{\mathcal{S}} = \|Kf\|_{\mathcal{O}}^2 + \alpha \langle Tf, f \rangle_{\mathcal{S}}. \quad (43)$$

По предположению, $T > 0$ означает $\langle Tf, f \rangle_{\mathcal{S}} \geq m_T \|f\|_{\mathcal{S}}^2$ для некоторого $m_T > 0$. Следовательно,

$$\langle Af, f \rangle_{\mathcal{S}} \geq \alpha m_T \|f\|_{\mathcal{S}}^2 > 0, \quad (44)$$

откуда следует положительная определенность A . $\square$

Теорема 1. Пусть $\mathcal{S}, \mathcal{F}$ – гильбертовы пространства, $\mathcal{O} = \mathbb{R}^n$ – евклидово пространство (n – конечное число датчиков), $T : \mathcal{S} \rightarrow \mathcal{F}$ и $C : \mathcal{F} \rightarrow \mathcal{O}$ – ограниченные линейные операторы, T – положительно определенный оператор. Пусть $\alpha > 0$, $\beta \geq 0$ и $\text{TV} : \mathcal{S} \rightarrow [0, +\infty]$ – выпуклый функционал. Тогда функционал (42) строго выпукл и имеет единственный глобальный минимум.

Доказательство. Разложим функционал и проанализируем каждый компонент, используя свойства операторов и конечномерность пространства наблюдений.

Шаг 1: Анализ квадратичного компонента.

Рассмотрим

$$F(f) = \|Kf - d\|_{\mathcal{O}}^2 + \frac{\alpha}{2} \langle Tf, f \rangle_{\mathcal{S}}. \quad (45)$$

Первый член – норма в конечномерном евклидовом пространстве $\mathcal{O} = \mathbb{R}^n$ (где n – число датчиков). Ее можно переписать через сопряженный оператор $K^* : \mathcal{O} \rightarrow \mathcal{S}$:

$$\|Kf - d\|_{\mathcal{O}}^2 = \langle Kf - d, Kf - d \rangle_{\mathcal{O}} = \langle K^*Kf, f \rangle_{\mathcal{S}} - 2\langle K^*d, f \rangle_{\mathcal{S}} + \|d\|_{\mathcal{O}}^2. \quad (46)$$

Оператор K^*K является композицией $K^* : \mathbb{R}^n \rightarrow \mathcal{S}$ и $K : \mathcal{S} \rightarrow \mathbb{R}^n$. Поскольку $\mathcal{O} = \mathbb{R}^n$ конечномерно, оператор K^*K имеет **конечный ранг не выше n** . Он положительно полуопределен:

$$\langle K^*Kf, f \rangle_{\mathcal{S}} = \|Kf\|_{\mathcal{O}}^2 \geq 0 \quad \forall f \in \mathcal{S}. \quad (47)$$

Второй член в F – энергетический штраф. Поскольку T положительно определен, имеем:

$$\langle Tf, f \rangle_{\mathcal{S}} > 0 \quad \forall f \neq 0 \in \mathcal{S}. \quad (48)$$

Шаг 2: Строгая выпуклость F и роль конечномерности.

Функционал F квадратичен:

$$F(f) = \langle Af, f \rangle_{\mathcal{S}} - 2\langle b, f \rangle_{\mathcal{S}} + c, \quad (49)$$

где $A = K^*K + \frac{\alpha}{2}T$, $b = K^*d$, $c = \|d\|_{\mathcal{O}}^2$.

Ключевое свойство: оператор A является суммой оператора K^*K (конечного ранга, положительно полуопределенного) и оператора $\frac{\alpha}{2}T$ (положительно определенного на всем $\mathcal{S}$). При $\alpha > 0$ энергетический оператор T дополняет ранга оператора K^*K до полного ранга. Для любого $f \neq 0$:

$$\langle Af, f \rangle_{\mathcal{S}} = \langle K^*Kf, f \rangle_{\mathcal{S}} + \frac{\alpha}{2}\langle Tf, f \rangle_{\mathcal{S}} \geq \frac{\alpha}{2}m_T\|f\|_{\mathcal{S}}^2 > 0, \quad (50)$$

где $m_T > 0$ – константа такая, что $\langle Tf, f \rangle_{\mathcal{S}} \geq m_T\|f\|_{\mathcal{S}}^2$ для всех $f \in \mathcal{S}$ (существует по положительной определенности T). Таким образом, оператор A положительно определен, и квадратичный функционал F строго выпуклый.

Шаг 3: Свойства полной вариации.

Функционал полной вариации $\text{TV} : \mathcal{S} \rightarrow [0, +\infty]$ по определению выпуклый: для всех $f_1, f_2 \in \mathcal{S}$ и $\lambda \in [0, 1]$:

$$\text{TV}(\lambda f_1 + (1 - \lambda)f_2) \leq \lambda \text{TV}(f_1) + (1 - \lambda) \text{TV}(f_2). \quad (51)$$

Кроме того, TV является нижнеполунепрерывным функционалом в слабой топологии пространства $\mathcal{S}$.

Шаг 4: Строгая выпуклость суммы.

Сумма

$$J(f) = F(f) + \beta \text{TV}(f) \quad (52)$$

при $\beta \geq 0$ остается строго выпуклой, поскольку F строго выпукла. Для всех $f_1 \neq f_2$ и $\lambda \in (0, 1)$:

$$J(\lambda f_1 + (1 - \lambda)f_2) < \lambda J(f_1) + (1 - \lambda)J(f_2). \quad (53)$$

Шаг 5: Коэрцитивность и существование минимума.

Функционал J коэрцитивен: $J(f) \rightarrow +\infty$ при $\|f\|_{\mathcal{S}} \rightarrow \infty$. Это следует из того, что:

$$J(f) \geq \langle K^* K f, f \rangle_{\mathcal{S}} + \frac{\alpha}{2} \langle T f, f \rangle_{\mathcal{S}} - 2 \|K^* d\|_{\mathcal{S}} \|f\|_{\mathcal{S}} \geq c_1 \|f\|_{\mathcal{S}}^2 - c_2 \|f\|_{\mathcal{S}}, \quad (54)$$

где $c_1 > 0$ – константа положительной определенности A , а c_2 – ограниченная константа.

Поскольку J строго выпуклый, нижнеполунепрерывный и коэрцитивный на гильбертовом пространстве $\mathcal{S}$, он имеет *единственный* глобальный минимум $f^* \in \mathcal{S}$. $\square$

Замечание 2. Теорема 1 показывает, что введение энергетической регуляризации $\frac{\alpha}{2} \langle T f, f \rangle_{\mathcal{S}}$ позволяет обеспечивать единственность решения. Но она не говорит о том, что решение будет принадлежать множеству решений исходного СЛАУ $K f = d$. При $\alpha > 0$ оптимальное решение f^* будет отличаться от любого решения f_0 исходного СЛАУ, так как энергетический штраф смещает оптимум в сторону решений с меньшей энергией.

1. **Конечномерность пространства наблюдений:** Поскольку $\mathcal{O} = \mathbb{R}^n$ (где n – число датчиков), оператор $K^* K$ имеет конечный ранг, не превышающий n . При $\dim \mathcal{S} > n$ (пространство источников имеет большую размерность, чем пространство наблюдений) задача становится неопределенной. При $\dim \mathcal{S} < n$ задача не имеет смысла.
2. **Роль энергетического оператора T :** Энергетический штраф $\alpha \langle T f, f \rangle_{\mathcal{S}}$ на всем пространстве $\mathcal{S}$ и не зависит от конечномерности $\mathcal{O}$. Он обеспечивает положительную определенность функционала, компенсируя недостаток информации от конечного числа датчиков.
3. **Недостаточность одной регуляризации:** Без энергетического члена ($\alpha = 0$): при $\dim \mathcal{S} > n$ функционал $\|K f - d\|_{\mathcal{O}}^2$ имеет бесконечномерное множество решений (полное аффинное подпространство размерности $\dim \mathcal{S} - n > 0$). Добавление TV-регуляризации $\beta \text{TV}(f)$ не обеспечивает единственность. Без структурной регуляризации ($\beta = 0$): решение физически неправдоподобное и излишне гладкое в пространстве источников.

5.7. Анализ аппроксимации оператора прямой задачи

На практике оператор T неизвестен, а известна аппроксимация оператора прямой задачи T_n . В работе рассматривается аппроксимация нейросетью для прямой задачи методом nPDE [7]. В качестве аппроксимации также может выступать численное решение методом конечных разностей. Рассмотрим последовательность функционалов

$$J_n(f) = \|C T_n f - d\|_{\mathcal{O}}^2 + \frac{\alpha}{2} \langle T_n f, f \rangle_{\mathcal{S}} + \beta \text{TV}(f), \quad (55)$$

где $\mathcal{S}, \mathcal{F}, \mathcal{O}$ – гильбертовы пространства, $T, T_n : \mathcal{S} \rightarrow \mathcal{F}$ – ограниченные линейные операторы, $C : \mathcal{F} \rightarrow \mathcal{O}$ – ограниченный линейный оператор наблюдения, $\alpha > 0$, $\beta \geq 0$, а $\text{TV} : \mathcal{S} \rightarrow [0, +\infty]$ – выпуклый нижнеполунепрерывный функционал. Оператор T является положительно определенным оператором потенциала: существует $m_T > 0$ такое, что $\langle Tf, f \rangle_{\mathcal{S}} \geq m_T \|f\|_{\mathcal{S}}^2$ для всех $f \in \mathcal{S}$. Квадратичная форма $\langle Tf, f \rangle_{\mathcal{S}}$ соответствует энергии взаимодействия поля с источниками.

Теорема 2 (Сходимость минимизаторов). *Пусть выполнены следующие условия:*

1. $T_n \rightarrow T$ равномерно на ограниченном множестве $\mathcal{S}$, то есть $\forall R > 0$: $\sup_{\|f\|_{\mathcal{S}} \leq R} \|T_n f - T f\|_{\mathcal{F}} \rightarrow 0$ при $n \rightarrow \infty$.
2. Существует $M > 0$ такое, что $\sup_n \|T_n\|_{\mathcal{L}(\mathcal{S}, \mathcal{F})} \leq M$ (равномерная ограниченность).
3. Оператор $C : \mathcal{F} \rightarrow \mathcal{O}$ ограничен.
4. Оператор T положительно определен: $\exists m_T > 0$ такое, что $\langle Tf, f \rangle_{\mathcal{S}} \geq m_T \|f\|_{\mathcal{S}}^2$ для всех $f \in \mathcal{S}$ (коэрцитивность энергетического члена).
5. Функционал TV ограничен снизу и коэрцитивен: $\text{TV}(f) \geq c\|f\|_{\mathcal{S}} - d$ для некоторых $c > 0, d \geq 0$.

Обозначим $J(f) = \|CTf - d\|_{\mathcal{O}}^2 + \frac{\alpha}{2} \langle Tf, f \rangle_{\mathcal{S}} + \beta \text{TV}(f)$. Пусть f_n^* – единственный глобальный минимум J_n , а f^* – единственный глобальный минимум J . Тогда $f_n^* \rightarrow f^*$ сильно в норме $\mathcal{S}$ при $n \rightarrow \infty$.

Доказательство. **1. Коэрцитивность и ограниченность.** Для любого $f \in \mathcal{S}$ имеем

$$\begin{aligned} J_n(f) &\geq \|CT_n f - d\|_{\mathcal{O}}^2 + \frac{\alpha}{2} \langle T_n f, f \rangle_{\mathcal{S}} + \beta \text{TV}(f) \\ &\geq \frac{\alpha}{2} \langle T_n f, f \rangle_{\mathcal{S}} + \beta(c\|f\|_{\mathcal{S}} - d). \end{aligned}$$

Так как семейство $\{T_n\}$ равномерно ограничено, существует константа $C_1 > 0$ такая, что $|\langle T_n f, f \rangle_{\mathcal{S}}| \leq C_1 \|f\|_{\mathcal{S}}^2$. По условию (4) для точного оператора T имеем $\langle Tf, f \rangle_{\mathcal{S}} \geq m_T \|f\|_{\mathcal{S}}^2$. В силу равномерной сходимости $T_n \rightarrow T$ на шарах, можно показать, что существует N и $\tilde{m} > 0$ такие, что для всех $n \geq N$ и всех $f \in \mathcal{S}$:

$$\langle T_n f, f \rangle_{\mathcal{S}} \geq \tilde{m} \|f\|_{\mathcal{S}}^2. \quad (56)$$

Следовательно, для больших n функционалы J_n коэрцитивны:

$$J_n(f) \geq \frac{\alpha}{2} \tilde{m} \|f\|_{\mathcal{S}}^2 + \beta c \|f\|_{\mathcal{S}} - \beta d - C_2 \rightarrow +\infty \quad \text{при } \|f\|_{\mathcal{S}} \rightarrow \infty. \quad (57)$$

Поскольку $J_n(f_n^*) \leq J_n(0) = \|d\|_{\mathcal{O}}^2 + \beta \text{TV}(0) < \infty$, последовательность $\{f_n^*\}$ ограничена в $\mathcal{S}$.

2. Слабая сходимость подпоследовательности. Так как $\mathcal{S}$ рефлексивно, из ограниченной последовательности можно выделить слабо сходящуюся подпоследовательность (обозначаем ее также $\{f_n^*\}$): $f_n^* \rightharpoonup \bar{f}$ в $\mathcal{S}$.

3. Нижний предел функционалов. Функционал $f \mapsto \|CTf - d\|_{\mathcal{O}}^2$ непрерывен по сильной топологии и, следовательно, слабо нижнеполунепрерывен. Функционал $f \mapsto \langle Tf, f \rangle_{\mathcal{S}}$ является квадратичной формой, соответствующей ограниченному самосопряженному оператору T (так как T положительно определен), и также слабо нижнеполунепрерывен. Функционал TV по условию слабо нижнеполунепрерывен. Сумма слабо нижнеполунепрерывных функционалов является слабо нижнеполунепрерывной. Поэтому

$$J(\bar{f}) \leq \liminf_{n \rightarrow \infty} J(f_n^*). \quad (58)$$

4. Оценка $\limsup$. Так как f_n^* – минимум J_n , для любого $f \in \mathcal{S}$ (в частности для f^*) имеем $J_n(f_n^*) \leq J_n(f^*)$. Значит,

$$\limsup_{n \rightarrow \infty} J_n(f_n^*) \leq \limsup_{n \rightarrow \infty} J_n(f^*). \quad (59)$$

Поскольку $T_n \rightarrow T$ равномерно на ограниченных множествах, а f^* фиксирован, $T_n f^* \rightarrow T f^*$ сильно в $\mathcal{F}$. Тогда $\|CT_n f^* - d\|_{\mathcal{O}}^2 \rightarrow \|CT f^* - d\|_{\mathcal{O}}^2$ и $\langle T_n f^*, f^* \rangle_{\mathcal{S}} \rightarrow \langle T f^*, f^* \rangle_{\mathcal{S}}$. Следовательно, $\limsup_{n \rightarrow \infty} J_n(f^*) = J(f^*)$.

5. Предел. Собираем неравенства:

$$J(\bar{f}) \leq \liminf_{n \rightarrow \infty} J_n(f_n^*) \leq \limsup_{n \rightarrow \infty} J_n(f_n^*) \leq J(f^*). \quad (60)$$

Так как f^* – единственный глобальный минимум J , имеем $J(\bar{f}) \geq J(f^*)$. Отсюда $J(\bar{f}) = J(f^*)$ и $\bar{f} = f^*$.

6. Сильная сходимость. Все слабые предельные точки последовательности $\{f_n^*\}$ совпадают с f^* , следовательно, $f_n^* \rightharpoonup f^*$ в $\mathcal{S}$. Остается доказать сильную сходимость. Рассмотрим разность:

$$\begin{aligned} \frac{\alpha}{2} \langle T_n f_n^*, f_n^* \rangle_{\mathcal{S}} - \frac{\alpha}{2} \langle T f^*, f^* \rangle_{\mathcal{S}} &= J_n(f_n^*) - \|CT_n f_n^* - d\|_{\mathcal{O}}^2 - \beta \text{TV}(f_n^*) \\ &\quad - (J(f^*) - \|CT f^* - d\|_{\mathcal{O}}^2 - \beta \text{TV}(f^*)). \end{aligned}$$

Так как $J_n(f_n^*) \rightarrow J(f^*)$ (из цепочки неравенств выше), $\|CT_n f_n^* - d\|_{\mathcal{O}}^2 \rightarrow \|CT f^* - d\|_{\mathcal{O}}^2$ по слабой сходимости и компактности: $T_n f_n^* = (T_n - T)f_n^* + T f_n^*$. Первое слагаемое стремится к нулю по равномерной сходимости $T_n \rightarrow T$ на ограниченном множестве, второе слабо сходится к $T f^*$. Тогда $CT_n f_n^* \rightharpoonup CT f^*$ в $\mathcal{O}$, а норма квадрата слабо нижнеполунепрерывна. Если $u_n \rightharpoonup u$ и $\|u_n\| \rightarrow \|u\|$, то последовательность $u_n \rightarrow u$ сходится сильно. Здесь $u_n = CT_n f_n^*$, $u = CT f^*$. Равенство пределов норм следует из сходимости значений функционалов и

$\text{TV}(f_n^*) \rightarrow \text{TV}(f^*)$ (так как TV слабо нижнеполунепрерывен и пределы совпадают). Получаем

$$\langle T_n f_n^*, f_n^* \rangle_{\mathcal{S}} \rightarrow \langle T f^*, f^* \rangle_{\mathcal{S}}. \quad (61)$$

Разложим:

$$\langle T_n f_n^*, f_n^* \rangle_{\mathcal{S}} = \langle T f_n^*, f_n^* \rangle_{\mathcal{S}} + \langle (T_n - T) f_n^*, f_n^* \rangle_{\mathcal{S}}. \quad (62)$$

Второе слагаемое стремится к нулю, так как $\|(T_n - T) f_n^*\|_{\mathcal{F}} \rightarrow 0$ (равномерная сходимость на ограниченных множествах). Следовательно, $\langle T f_n^*, f_n^* \rangle_{\mathcal{S}} \rightarrow \langle T f^*, f^* \rangle_{\mathcal{S}}$. Так как форма $\langle T \cdot, \cdot \rangle_{\mathcal{S}}$ коэрцитивна (условие 4), это влечет сильную сходимость $f_n^* \rightarrow f^*$ в $\mathcal{S}$. $\square$

5.8. Схема решения обратной задачи

Рассмотрим обратную задачу восстановления распределения источников $s \in \mathcal{S}$ по наблюдаемым данным $d \in \mathcal{O}$ в рамках операторной постановки $d = Ks + \eta$, где $K = C \circ T$ — композиция оператора решения прямой задачи $T : \mathcal{S} \rightarrow \mathcal{F}$ и оператора наблюдения $C : \mathcal{F} \rightarrow \mathcal{O}$. Для обеспечения единственности и устойчивости решения вводится регуляризованный функционал:

$$J(s) = \|Ks - d\|_{\mathcal{O}}^2 + \alpha \mathcal{R}_E(s) + \beta \mathcal{R}_{TV}(s), \quad (63)$$

где $\mathcal{R}_E(s) = \langle Ts, s \rangle_{\mathcal{S}}$ — энергетический регуляризатор, $\mathcal{R}_{TV}(s)$ — функционал полной вариации, $\alpha > 0$ и $\beta \geq 0$ — параметры регуляризации.

5.8.1. Аппроксимация оператора прямой задачи и сходимость решений

Пусть оператор прямой задачи T аппроксимируется последовательностью операторов $T_n : \mathcal{S} \rightarrow \mathcal{F}$, сходящихся к T в равномерной операторной топологии на ограниченных множествах. Введем аппроксимированный оператор наблюдения $K_n = C \circ T_n$ и соответствующий регуляризованный функционал:

$$J_n(s) = \|K_n s - d\|_{\mathcal{O}}^2 + \alpha \langle T_n s, s \rangle_{\mathcal{S}} + \beta \mathcal{R}_{TV}(s). \quad (64)$$

Минимизация функционала $J_n(s)$ по $s \in \mathcal{S}$ эквивалентна решению вариационной задачи:

$$s_n^* = \arg \min_{s \in \mathcal{S}} J_n(s). \quad (65)$$

Сходимость аппроксимированных решений s_n^* к точному решению s^* при $n \rightarrow \infty$ обеспечивается теоремой о сходимости минимизаторов (см. раздел 4.4).

5.8.2. Энергетическая регуляризация и ее свойства

Энергетический регуляризатор $\mathcal{R}_E(s) = \langle Ts, s \rangle_S$ вводится как квадратичная форма, соответствующая положительно определенному оператору потенциала T . В контексте электромагнитных задач эта форма интерпретируется как энергия взаимодействия поля с источниками:

$$\mathcal{R}_E(s) = \int_{\Omega} (\rho(\mathbf{r})\phi(\mathbf{r}) + \mathbf{A}(\mathbf{r}) \cdot \mathbf{j}(\mathbf{r})) d\mathbf{r}, \quad (66)$$

где $\rho = -\operatorname{div} \mathbf{P}$ — плотность заряда, $\mathbf{j} = \partial_t \mathbf{P}$ — плотность тока, ϕ и $\mathbf{A}$ — скалярный и векторный потенциалы, $\mathbf{P}$ — поляризация.

Свойства энергетического регуляризатора:

1. **Положительная определенность:** $\mathcal{R}_E(s) > 0$ для всех $s \neq 0$, что обеспечивает строгую выпуклость функционала $J(s)$.
2. **Физическая интерпретация:** минимизация $\mathcal{R}_E(s) = \langle Ts, s \rangle_S$ соответствует поиску решений с минимальной энергией взаимодействия поля с источниками, что согласуется с принципом наименьшего действия в электродинамике.
3. **Устойчивость:** при $\alpha > 0$ функционал $J(s)$ коэрцитивен и имеет единственный минимум даже в случае вырожденного оператора K .

5.8.3. Структурная регуляризация

В работе предлагается кроме энергетической регуляризации использовать функционал полной вариации $\mathcal{R}_{TV}(s)$ для получения разреженных источников. Без регуляризации на разреженность энергетический член будет способствовать разреженным решениям. Это связано с тем, что для разреженных источников энергия взаимодействия поля с другими источниками минимальна. Так расстояние до других будет большим, чем при точечных источниках. А точечные источники как раз дают максимальную энергию. В непрерывном случае функционал полной вариации $\mathcal{R}_{TV}(s)$ вводится как интеграл нормы градиента функции s :

$$\mathcal{R}_{TV}(s) = \sum_{\Omega} \|\nabla s(\mathbf{r})\| d\mathbf{r}. \quad (67)$$

В качестве аппроксимации берется оценка Монте-Карло $\rho = -\operatorname{div} \mathbf{P}$:

$$\mathcal{R}_{TV}(s) \approx \frac{1}{|\Omega|} \int_{\Omega} \sqrt{\|\nabla \rho(\mathbf{r})\|^2 + \varepsilon} d\mathbf{r}, \quad (68)$$

где $\varepsilon > 0$ — регуляризационный параметр, устраняющий сингулярность в точке 0.

Функционал обладает следующими

1. **Выпуклость:** $\mathcal{R}_{TV}(s)$ — выпуклый.
2. **Разреживание:** Минимум функционала $\mathcal{R}_{TV}(s)$ достигается тогда, когда носитель функции минимален

5.8.4. Метод минимизации регуляризованного функционала

Функционал $J(s)$ минимизируется с помощью градиентного спуска в пространстве $\mathcal{S}$. Градиент функционала $J(s)$ по s находится как:

$$\nabla_s J(s) = 2K^*(Ks - d) + \alpha T^*s + \beta \partial \mathcal{R}_{TV}(s), \quad (69)$$

где K^* — сопряженный оператор к K , T^* — сопряженный оператор к T , $\partial \mathcal{R}_{TV}(s)$ — субдифференциал функционала полной вариации.

5.8.5. Адаптивная регуляризация

Предлагается оптимизировать аппроксимацию оператора T и невязку данных $Ks = d$ одновременно. Для этого нужно делать спуск одновременно в направлении уменьшения ошибки аппроксимации оператора T и ошибки аппроксимации данных $Ks = d$. Нужно балансировать эти два направления, чтобы не допустить переобучения к данным при плохой аппроксимации оператора T и не допустить ухудшения аппроксимации данных при слишком сильной аппроксимации оператора T . Предлагается использовать адаптивную регуляризацию в виде мягкой барьерной функции, чтобы делать шаг одновременно в обоих направлениях.

$$\mathcal{B}(s) = \lambda_{\text{data}}(T + \alpha_{\text{data}}T^2), \quad T = \|Ks - d\|_{\mathcal{O}}^2 + \lambda_{\text{time}}\|\partial_t(Ks - d)\|_{\mathcal{O}}^2, \quad (70)$$

где $\lambda_{\text{data}} > 0$ — коэффициент функции потерь на данных, $\alpha_{\text{data}} > 0$ — коэффициент силы барьерной функции, $\lambda_{\text{time}} \geq 0$ — коэффициент функции потерь на производных.

Адаптивная настройка параметра λ_{data} осуществляется на основе оценки невязки данных и точности восстановления оператора T . Для решения прямой задачи в работе используется метод nPDE. Поэтому оценка точности T является суммой точности выполнения граничных условий и точности решения уравнения частных производных в области Ω . Такой подход обеспечивает баланс между точностью аппроксимации данных и точностью решения прямой задачи.

5.9. Граничные условия для прямой задачи

Для решения прямой задачи T необходимо задать граничные условия на границе области Ω . В работе предлагается брать в качестве граничного условия 0 для потенциала ϕ и вектора потенциала $\mathbf{A}$, что соответствует условию

Дирихле. Такое условие использовать в общем случае неверно. Поэтому предлагается использовать метод идеально согласованного слоя [11]. Он обеспечивает поглощение решения на небольшом слое на границе, без отражения волнового решения от границы. Это позволяет избежать искажения решения, связанного с неверными граничными условиями, и обеспечивает корректность оператора прямой задачи T в области Ω .

5.9.1. Свойства предложенного решения

Предложенное решение обладает следующими свойствами.

Из теоремы 2 следует, что распределения источников s_n^* , минимизирующие функционал $J_n(s)$ для приближенного решения T_n , сходятся к распределению источников s^* для точного функционала $J(s)$. Что позволяет использовать для нахождения решения прямой задачи метод nPDE. Достаточно раз небольшой шаг по источникам s и по оператору T .

Из теоремы 1, что решение регуляризованной задачи единственно, что позволяет решать задачу градиентным спуском, который не будет застревать в локальных минимумах. При этом введенная регуляризация позволяет априори мягко задавать структуру решений.

Таким образом, предложенная алгоритмическая схема обеспечивает корректное решение обратной задачи ЭЭГ. Обеспечивается физическая обоснованность решений, при этом не задается жесткая структура решений, а приближается нейросетью.

Сначала реализуется барьерное приближение условия $Kf = d$, затем условие смягчается и уточняется оператор наблюдения K , аппроксимируемый nPDE. Параметры λ_{data} , α_{data} и λ_{time} адаптивно настраиваются в процессе оптимизации для обеспечения баланса между точностью аппроксимации данных и устойчивостью решения. При этом достигается сходимость самого оператора, восстанавливающего решение прямой задачи, и решения обратной задачи, удовлетворяющего данным.

6. Анализ линейных моделей в контексте обратных задач

В рамках исследования обратных задач для нейронных дифференциальных уравнений в частных производных (nPDE) представляет интерес анализ линейных моделей, основанных на разложении решения по заданному базису функций. Рассмотрим подход, предложенный в работе [12], где в отличие от методов независимых компонент (ICA) используется векторное пространство функций $\mathcal{H}$ с базисом $\{\psi_i\}_{i=1}^{\infty}$.

Пусть распределение источников $s \in \mathcal{S}$ представляется в виде разложения по базису $\{\psi_i\}$:

$$s(\mathbf{r}, t) = \sum_{i=1}^{\infty} c_i \psi_i(\mathbf{r}, t), \quad (71)$$

где $\{c_i\}_{i=1}^{\infty}$ — коэффициенты разложения. Тогда оператор прямой задачи $T : \mathcal{S} \rightarrow \mathcal{F}$ действует на элемент s как:

$$Ts = \sum_{i=1}^{\infty} c_i T\psi_i, \quad (72)$$

а наблюдаемые данные $d \in \mathcal{O}$ выражаются через оператор наблюдения $C : \mathcal{F} \rightarrow \mathcal{O}$:

$$d = CTs + \eta = \sum_{i=1}^{\infty} c_i CT\psi_i + \eta, \quad (73)$$

где $\eta \in \mathcal{O}$ — аддитивный шум.

Введем матрицу Грама $\mathbf{G} \in \mathbb{R}^{n \times n}$ с элементами $G_{ij} = \langle CT\psi_i, CT\psi_j \rangle_{\mathcal{O}}$ и вектор $\mathbf{b} \in \mathbb{R}^n$ с компонентами $b_i = \langle d, CT\psi_i \rangle_{\mathcal{O}}$. Тогда задача восстановления коэффициентов $\{c_i\}$ сводится к решению системы линейных уравнений:

$$\mathbf{G}\mathbf{c} = \mathbf{b}, \quad (74)$$

где $\mathbf{c} = (c_1, \dots, c_n)^{\top}$ — вектор коэффициентов.

Для обеспечения устойчивости решения вводится регуляризованный функционал:

$$J(\mathbf{c}) = \|\mathbf{G}\mathbf{c} - \mathbf{b}\|_2^2 + \alpha \mathbf{c}^{\top} \mathbf{T} \mathbf{c} + \beta \mathcal{R}_{TV}(\mathbf{c}), \quad (75)$$

где $\mathbf{T}$ — матрица энергетического регуляризатора с элементами $T_{ij} = \langle T\psi_i, T\psi_j \rangle_{\mathcal{F}}$, $\mathcal{R}_{TV}(\mathbf{c})$ — дискретный аналог функционала полной вариации.

Теорема 3 (Единственность решения линейной задачи). *Пусть матрица $\mathbf{G} + \alpha \mathbf{T}$ положительно определена. Тогда регуляризованная задача имеет единственное решение $\mathbf{c}^*$, минимизирующее функционал $J(\mathbf{c})$.*

Доказательство. Матрица $\mathbf{G} + \alpha \mathbf{T}$ положительно определена по условию, следовательно, функционал $J(\mathbf{c})$ строго выпукл. Это гарантирует существование и единственность минимума $\mathbf{c}^*$. $\square$

Таким образом, линейные модели, основанные на разложении по базису функций, предоставляют теоретически обоснованный подход к решению обратных задач, согласованный с предложенной в работе регуляризацией на основе энергетического функционала и полной вариации.

7. Вычислительный эксперимент

Для подтверждения теоретических результатов и оценки практической эффективности предложенного метода проводятся вычислительные эксперименты на реальных и синтетических данных. На реальных данных проверяется способность метода восстанавливать потенциал на датчиках. Синтетические данные используются для оценки точности восстановления распределения источников и потенциалов во внутренней области головы Ω . В качестве реальных данных используются данные проекта Brunton et al. (`brunton_uw_bio`), в них представлены результаты измерений ЭЭГ-сигнала в ходе выполнения различных когнитивных и моторных задач. Синтетические данные были сгенерированы для модели овальной головы с заданными дипольными источниками, что позволяет контролировать условия эксперимента и оценить точность восстановления.

8. Эксперименты

Целью эксперимента является оценка точности восстановления распределения источников $s \in \mathcal{S}$ и потенциалов $\phi \in \mathcal{F}$ по наблюдаемым данным $d \in \mathcal{O}$. Требуется сравнить предложенный метод с существующими подходами. Для оценки качества восстановления предлагается использовать следующие метрики.

- **Sensor MSE**: среднеквадратичная ошибка восстановления потенциала на датчиках, расположенных на поверхности головы $\Gamma = \partial\Omega$.
- **Deep MSE**: среднеквадратичная ошибка восстановления полей и источников во внутренней области Ω .

8.1. Эксперимент 1: Реальные данные проекта Brunton et al.

В реальных данных нет возможности оценить потенциал и источники внутри. В работе предлагается оценить точность моделирования источников по тому, как модели восстанавливают пропущенные данные. В каждый момент времени пропускается половина данных от источников, модели восстанавливают пропущенные данные, обучаются на оставшихся. Ошибка считается по тому, как модели восстановили пропущенные данные. Результаты эксперимента представлены в таблице 1.

Метод	Sensor MSE	Примечания
Предложенный метод	—	
LORETA	—	

Таблица 1: Сравнение методов по реальным данным Brunton et al.

Результаты показывают, что предложенный метод обеспечивает сопоставимую точность восстановления потенциала на датчиках (Sensor MSE) по сравнению с LORETA. Но при этом позволяет контролировать свойства восстанавливаемых решений во внутренней области Ω за счет использования энергетической регуляризации $\mathcal{R}_E(s)$ и TV-регуляризации $\mathcal{R}_{TV}(s)$, что является преимуществом по сравнению с LORETA, которая использует заранее заданные предположения об источниках как токах диполей.

8.2. Эксперимент 2: Синтетические данные

В данном эксперименте предлагается смоделировать дипольные источники в коре головного мозга Ω . Предлагается взять овальную модель головы. Датчики $n = 16$ располагаются на поверхности головы Γ ближе к затылочной части головы с частотой дискретизации 50 Гц. На рисунке 4 представлена визуализация сгенерированных данных.




Рис. 4: Визуализация синтетической модели головы с расположением датчиков и источников.

Синтетические данные позволяют оценить точность восстановления как на поверхности (Sensor MSE), так и во внутренней области (Deep MSE). Результаты эксперимента представлены в таблице 2.

Метод	Sensor MSE	Deep MSE
Предложенный метод	—	—
LORETA	—	—

Таблица 2: Сравнение методов по синтетическим данным.

9. Результаты

Предложенный метод показывает сопоставимые с LORETA результаты восстановления пропущенных значений на датчиках. Что подтверждает теоретические результаты о сходимости предложенного метода. Способность метода восстанавливать пропущенные данные с источников говорит о корректности предложенной модели источников и использовании уравнений Максвелла для расчета электромагнитного сигнала.

Предложенный метод более точно локализует источник сигнала по оценке потенциала внутри Деер MSE. Что говорит о более корректной физической модели, чем в LORETA. При этом стоит отметить, что для достижения заданной точности требуется заранее настроить пространственную регуляризацию α , β . Поэтому требуется сделать предположения о свойствах источников, хотя и более слабые, чем у LORETA.

При этом метод поддерживает электродинамические решения по умолчанию. Не делаются предположения о квазистатичности решения, а используются уравнения Максвелла без изменений и дополнительных предположений. В качестве недостатков можно заметить, что при неверной настройке гиперпараметров, особенно для барьерной функции, метод перестает сходиться полностью.

10. Заключение

В работе предложен метод решения обратной задачи уравнений в частных производных с помощью физико-информированного подхода. Предложенный метод не накладывает жестких ограничений на структуру источников, а использует мягкую регуляризацию на энергию и разреженность источников. Предложенный метод использует физико-информированный подход и использует априорные знания о формировании сигнала ЭЭГ. Он обеспечивает более точную локализацию источников по сравнению с классическими методами. Доказаны теоретические результаты о сходимости предложенных методов и сходимости нейросетевого метода. Предложен метод аппроксимации прямой задачи через nPDE-подход и через разложение по базису.

Недостатком метода является чувствительность гиперпараметров, так как нужно поддерживать сходимость решения прямой задачи и восстановления распределения источников одновременно. В качестве дальнейшего исследования предлагается рассмотреть метод восстановления оператора решения прямой задачи уравнения Максвелла. Это устранил необходимость делать оптимизационные шаги в двух направлениях одновременно.

Список литературы

1. *Pascual-Marqui Roberto D.* Low Resolution Brain Electromagnetic Tomography (LORETA): The Technique, Its Validation, and Methods of Analysis // *Journal of Neurotherapy*. — 2001. — Vol. 4, no. 4. — Pp. 31–33.
2. Review on solving the inverse problem in EEG source analysis / Roberta Grech, Tracey Cassar, Joseph Muscat et al. // *Journal of NeuroEngineering and Rehabilitation*. — 2008. — ноябрь. — Vol. 5, no. 1.
3. *Weinstein David M., Zhukov Leonid, Johnson Chris R.* Lead Field Basis for FEM Source Localization. — 1999. — URL: <https://api.semanticscholar.org/CorpusID:11683372>.
4. Enhancing Brain Source Reconstruction by Initializing 3D Neural Networks with Physical Inverse Solutions / Marco Morik, Ali Hashemi, Klaus-Robert Müller et al. // *IEEE Transactions on Medical Imaging (Volume: 45, Issue: 1, pp. 231 - 242, 2026)*. — 2024. — январь. — Vol. 45, no. 1. — Pp. 231–242.
5. Inverse EEG Problem, Minimization and Numerical Solutions / Georgina Paraskevopoulou, Athanassios S. Fokas, Antonios Charalambopoulos, Stavros Perantonis // *Chaos, Fractals and Complexity*. — Springer International Publishing, 2023. — Pp. 189–198.
6. Sparse wavelet-based solutions for the M/EEG inverse problem / Samy Mokhtari, Jean-Michel Badier, Christian G. Bénar, Bruno Torrèsani // *Sampling Theory and Applications (SampTA) 2023, Smita Krishnaswamy, Bastian Rieck, Ian Adelstein and Guy Wolf, Jul 2023, New Haven (Yale University), United States*. — 2023. — июнь.
7. *Zubov Kirill, McCarthy Zoe, Ma Yingbo et al.* NeuralPDE: Automating Physics-Informed Neural Networks (PINNs) with Error Approximations. — 2021.
8. *Billingsley Patrick.* Probability and Measure. — 3rd edition. — New York: John Wiley & Sons, 1995.
9. *van der Vaart Aad W.* Asymptotic Statistics. — Cambridge, UK: Cambridge University Press, 1998.
10. *Hoeffding Wassily.* Probability inequalities for sums of bounded random variables // *Journal of the American Statistical Association*. — 1963. — Vol. 58, no. 301. — Pp. 13–30.
11. *Bécache E., Dhia A. S. Bonnet-Ben, Legendre G.* Perfectly Matched Layers for the Convected Helmholtz Equation // *SIAM Journal on Numerical Analysis*. — 2004. — январь. — Vol. 42, no. 1. — Pp. 409–433.

12. Functional principal component analysis for incomplete space–time data / Alessandro Palummo, Eleonora Arnone, Luca Formaggia, Laura M. Sangalli // *Environmental and Ecological Statistics*. — 2024. — март. — Vol. 31, no. 2. — Pp. 555–582.